

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais
Abertos e Proprietários para Extração de
Respostas em Provas Objetivas Manuscritas.**

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais Abertos
e Proprietários para Extração de Respostas em Provas
Objetivas Manuscritas.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Instituto Federal Catarinense – IFC

Câmpus Araquari

Sistemas de Informação

Orientador: Prof. Dr. Fabio Longo de Moura

Coorientador: Prof. Dr. Paulo Cesar Fernandes de Oliveira

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

Avaliação Comparativa de Modelos Multimodais Abertos e Proprietários para Extração de Respostas em Provas Objetivas Manuscritas. / Gabriel Lopes Pereira.
– Araquari – SC, Abril de 2026-
36 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Fabio Longo de Moura

Monografia (Graduação) – Instituto Federal Catarinense – IFC
Câmpus Araquari
Sistemas de Informação, Abril de 2026.

1. Inteligência Artificial. 2. Modelos Multimodais. 3. Sistemas de Informação.
4. Processamento de Documentos. I. Gabriel Pereira. II. Instituto Federal Catarinense. III. Câmpus Araquari. IV. Avaliação Comparativa de Modelos Multimodais Abertos e Proprietários para Extração de Respostas em Provas Objetivas Manuscritas.

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais Abertos
e Proprietários para Extração de Respostas em Provas
Objetivas Manuscritas.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Araquari – SC
Abril de 2026

“Aquele que não tem paciência com as pequenas coisas, falhará nos grandes planos.”
- Confúcio

Resumo

Este trabalho propõe a avaliação comparativa de modelos multimodais aplicados à extração estruturada de informações em provas objetivas manuscritas. Neste trabalho, o termo provas objetivas manuscritas refere-se a avaliações em papel cuja estrutura objetiva é preservada, mas cujos elementos visuais podem estar escritos manualmente, incluindo identificação do aluno, enunciados, numeração das questões, alternativas e marcações de resposta. O foco está na área de Sistemas de Informação, considerando a construção de uma arquitetura plugável composta por aplicativo móvel, backend, adaptador de modelos, provedor de modelo aberto, provedor de modelo proprietário, validador de JSON, banco de dados e tela de validação humana. O aplicativo móvel não executa modelos localmente; sua função é capturar imagens e apresentar resultados. O processamento ocorre por meio de um modelo multimodal aberto hospedado em servidor próprio e de um modelo multimodal proprietário acessado por API externa. A metodologia adota Design Science Research para orientar o desenvolvimento do artefato e um experimento comparativo para avaliar acurácia, validade da saída estruturada, latência, custo operacional, robustez e necessidade de intervenção humana. Espera-se que o resultado indique qual abordagem técnica é mais adequada ao cenário estudado, considerando não apenas o desempenho dos modelos, mas também aspectos de integração, governança, substituibilidade e confiabilidade do fluxo.

Palavras-chave: Modelos multimodais. Sistemas de Informação. Processamento de documentos. JSON. Validação humana.

Lista de abreviaturas e siglas

ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface (Interface de Programação de Aplicações)
DSR	Design Science Research
FEDS	Framework for Evaluation in Design Science
GPT	Generative Pre-trained Transformer
IA	Inteligência Artificial
IDP	Intelligent Document Processing (Processamento Inteligente de Documentos)
IFG	Instituto Federal de Goiás
JSON	JavaScript Object Notation
LGPD	Lei Geral de Proteção de Dados
LLM	Large Language Model (Modelo de Linguagem de Grande Escala)
MLLM	Multimodal Large Language Model (Modelo de Linguagem de Grande Escala Multimodal)
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)
OMR	Optical Mark Recognition (Reconhecimento Óptico de Marcas)
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
SIGAA	Sistema Integrado de Gestão de Atividades Acadêmicas
SUS	System Usability Scale (Escala de Usabilidade de Sistema)
TCC	Trabalho de Conclusão de Curso
USP	Universidade de São Paulo

Sumário

1	INTRODUÇÃO	9
1.1	Contextualização	9
1.2	Tema e Delimitação	10
1.3	Problema	11
1.3.1	Extração Confiável de Dados Visuais	11
1.3.2	Comparabilidade entre Provedores	11
1.3.3	Padronização e Validação da Saída	11
1.3.4	Interação Humana no Controle de Qualidade	12
1.4	Justificativa	12
1.4.1	Objetivo geral	13
1.4.2	Objetivos específicos	13
1.5	Organização do trabalho	14
2	REFERENCIAL TEÓRICO	15
2.1	Processamento de Documentos Manuscritos	15
2.2	Modelos Multimodais	15
2.3	Modelos Abertos e Modelos Proprietários	16
2.4	Arquiteturas Plugáveis em Sistemas de Informação	16
2.5	Saída Estruturada e Validação Humana	17
2.6	Design Science Research e Avaliação de Artefatos	17
2.7	Trabalhos Relacionados	18
2.8	Síntese do Referencial	19
3	METODOLOGIA	20
3.1	O Ciclo DSR	20
3.1.1	Identificação do Problema e Motivação	20
3.1.2	Definição dos Objetivos da Solução	20
3.1.3	Design e Desenvolvimento	20
3.1.4	Demonstração e Avaliação	20
3.1.5	Comunicação	21
3.2	Procedimentos Metodológicos	21
4	DESENVOLVIMENTO E EXPERIMENTO	22
4.1	Storyboard do Aplicativo	22
4.1.1	Entradas	22
4.1.2	Processamento	22

4.1.3	Saídas	23
4.1.4	Componentes	23
4.1.5	Fluxo de Extração	24
4.1.6	Contrato de Saída	24
4.2	Experimento Comparativo	25
4.2.1	Desenho Experimental	25
4.2.2	Cenários Avaliados	25
4.2.3	Métricas de Avaliação	25
4.2.4	Tabela Comparativa Planejada	26
4.2.5	Critério de Análise	26
4.3	Cronograma de Execução do Experimento	27
5	EXPECTATIVAS DE CONCLUSÃO E RESULTADOS ESPERADOS	28
5.1	Contribuição Científica e Prática	28
5.2	Resultados Esperados	28
5.3	Limites da Conclusão Esperada	29
6	CONCLUSÃO	30
6.1	Síntese dos Resultados Esperados	30
6.2	Considerações sobre Ética, Privacidade e Controle	30
6.3	Contribuições Esperadas	31
6.3.1	Contribuição Científica	31
6.3.2	Contribuição Técnica	31
6.4	Limitações do Estudo	32
6.5	Trabalhos Futuros	32
6.5.1	Ampliação dos Modelos Avaliados	32
6.5.2	Avaliação com Diferentes Formatos de Documento	32
6.5.3	Otimização do Fluxo	33
6.5.4	Expansão da Validação Humana	33
6.5.5	Integração com Sistemas Externos	33
6.5.6	Modelo Híbrido de Provedores	33
6.6	Considerações Finais	33
	REFERÊNCIAS	34

1 Introdução

1.1 Contextualização

O processamento de documentos manuscritos continua sendo um problema relevante para Sistemas de Informação, especialmente quando a entrada é capturada em papel, por câmera de dispositivo móvel, e precisa ser transformada em dados estruturados confiáveis. Neste trabalho, o termo provas objetivas manuscritas refere-se a avaliações em papel cuja estrutura objetiva é preservada, mas cujos elementos visuais podem estar escritos manualmente, incluindo identificação do aluno, enunciados, numeração das questões, alternativas e marcações de resposta.

O desafio técnico, portanto, não é apenas detectar marcações em um formulário impresso. A proposta envolve extrair dados estruturados de um documento manuscrito, no qual a informação de interesse pode aparecer em textos escritos à mão, marcações de resposta, rasuras, campos de identificação, leiautes irregulares e variações de iluminação, enquadramento e qualidade da imagem. Esse cenário torna o problema diferente de uma simples digitalização, pois exige um fluxo capaz de receber uma imagem não padronizada, identificar elementos estruturais, representar o resultado em formato computável e permitir validação humana quando houver incerteza.

Modelos voltados ao entendimento de documentos visuais passaram a combinar informação textual, visual e de leiaute para tarefas como extração de informação e resposta visual sobre documentos. Trabalhos como LayoutLM, DocVQA e Donut evidenciam a relevância desse campo para documentos visualmente ricos e não estruturados (XU et al., 2020; MATHEW; KARATZAS; JAWAHAR, 2021; KIM et al., 2022). Entretanto, a adoção desses modelos em sistemas reais envolve decisões arquiteturais que não se limitam à escolha do modelo com maior acurácia. Em um sistema de informação, também importam custo, latência, dependência de fornecedor, privacidade, possibilidade de auditoria, padronização de saída, tratamento de erros, integração com banco de dados e desenho de fluxos de validação.

Neste trabalho, o aplicativo móvel não executa modelos de IA localmente. Sua função é capturar a imagem da prova objetiva manuscrita, enviar a imagem ao backend e apresentar os resultados ao usuário. O processamento de IA ocorre fora do dispositivo móvel, por meio de dois tipos de provedores: um modelo multimodal aberto hospedado em servidor próprio e exposto como API, e um modelo multimodal proprietário acessado por API externa. A contribuição técnica está na arquitetura plugável que permite alternar esses provedores, no fluxo de extração estruturada de documento manuscrito, na padronização da

saída em JSON, na validação humana e na comparação experimental entre as abordagens.

1.2 Tema e Delimitação

O tema central deste Trabalho de Conclusão de Curso (TCC) é a avaliação comparativa de modelos multimodais aplicados à extração estruturada de informações em provas objetivas manuscritas. O trabalho está delimitado à construção e avaliação de um sistema de informação composto por aplicativo móvel, backend, adaptadores de modelos, provedores de IA, validador de saída estruturada, banco de dados e interface de validação humana.

O escopo contempla provas objetivas em papel, redigidas manualmente, nas quais enunciados, alternativas, identificação do aluno e marcações de resposta podem estar escritos à mão. Embora a prova seja manuscrita, o trabalho não busca corrigir semanticamente questões dissertativas. O foco permanece em avaliações objetivas, nas quais o sistema deve identificar elementos estruturais, como número da questão, alternativas disponíveis, alternativa escolhida, identificação do aluno, rasuras e ambiguidades visuais. Geração automática de provas, recomendação pedagógica e análise subjetiva de respostas ficam fora do escopo. A avaliação não tem como foco demonstrar que um aplicativo foi desenvolvido, mas verificar qual abordagem técnica se mostra mais adequada para a extração estruturada de informações: modelo aberto hospedado em infraestrutura própria ou modelo proprietário acessado por API externa.

O escopo técnico define o uso de três pilares fundamentais:

1. **Aplicativo móvel:** interface para captura das imagens das provas, seleção do provedor de IA e visualização dos resultados retornados pelo backend.
2. **Backend e orquestração:** serviço responsável por autenticação, armazenamento, acionamento do fluxo de extração, persistência dos resultados e exposição de APIs para o aplicativo.
3. **Camada plugável de IA:** componente *ModelAdapter* que normaliza a comunicação com um *OpenModelProvider*, hospedado em servidor próprio, e um *ClosedModelProvider*, acessado por API externa.

O sistema deverá produzir uma saída padronizada, em JSON, contendo identificação da prova, identificação do aluno quando disponível, questões identificadas, alternativas detectadas, respostas extraídas, nível de confiança, rasuras ou ambiguidades visuais e itens que exigem validação humana. Essa padronização permite comparar modelos diferentes sob o mesmo contrato de dados e evita que cada provedor imponha diretamente seu formato de resposta ao restante do sistema.

1.3 Problema

O problema de pesquisa deste trabalho pode ser formulado da seguinte maneira: como projetar e avaliar, no contexto de Sistemas de Informação, uma arquitetura plugável para extração estruturada de informações em provas objetivas manuscritas, permitindo comparar modelos multimodais abertos hospedados em infraestrutura própria e modelos multimodais proprietários acessados por API externa?

A questão central não é apenas automatizar uma atividade de correção, mas investigar como diferentes estratégias de provisão de IA afetam um sistema que precisa transformar imagens de documentos físicos em registros estruturados. Em particular, o trabalho considera quatro subproblemas técnicos:

1.3.1 Extração Confiável de Dados Visuais

As imagens das provas podem conter sombras, inclinação, borrões, baixa resolução, campos manuscritos, enunciados escritos à mão, alternativas manuscritas, marcações ambíguas e rasuras. O sistema precisa extrair elementos estruturais da avaliação sem assumir que a imagem terá condições ideais de captura, que o texto estará impresso ou que o usuário utilizará um scanner dedicado. O reconhecimento de manuscritos apresenta desafios próprios de variabilidade de escrita e qualidade de aquisição (PLAMONDON; SRIHARI, 2000; RASSUL et al., 2025), enquanto o entendimento de documentos requer o uso combinado de texto, imagem e leiaute (XU et al., 2020; MATHEW; KARATZAS; JAWAHAR, 2021; KIM et al., 2022).

1.3.2 Comparabilidade entre Provedores

Modelos abertos e proprietários podem retornar respostas em formatos distintos, possuir níveis diferentes de controle sobre prompts, custos, latência e disponibilidade. Sem uma camada de adaptação, a comparação entre provedores tende a ficar acoplada à implementação específica de cada API. O problema técnico consiste em isolar essas diferenças por meio de um contrato comum de entrada e saída.

1.3.3 Padronização e Validação da Saída

Como a saída do modelo será usada por um sistema transacional, ela precisa ser validada antes de ser persistida. O JSON retornado deve obedecer a um esquema previamente definido, conter campos obrigatórios, representar incertezas e permitir auditoria posterior. Respostas incompletas, inválidas ou incompatíveis com o esquema devem ser encaminhadas para tratamento automático ou validação humana.

1.3.4 Interação Humana no Controle de Qualidade

Mesmo com modelos multimodais, casos de baixa confiança ou respostas ambíguas devem ser apresentados ao usuário em uma tela de validação humana. Essa etapa é parte do sistema de informação, pois define como a decisão automatizada é revisada, corrigida, registrada e utilizada no resultado final.

1.4 Justificativa

A justificativa deste trabalho está na necessidade de compreender como modelos multimodais podem ser integrados a sistemas de informação que processam documentos físicos manuscritos. Embora a aplicação escolhida esteja situada no contexto de provas objetivas, a contribuição principal não é pedagógica. O foco está na arquitetura, na integração entre componentes, na extração estruturada de elementos visuais manuscritos, na normalização de dados gerados por IA, na validação de resultados e na comparação experimental de provedores tecnológicos.

Do ponto de vista técnico, comparar um modelo aberto hospedado em servidor próprio com um modelo proprietário via API externa permite observar trade-offs relevantes para Sistemas de Informação: controle operacional, privacidade, custo por processamento, latência, dependência de terceiros, facilidade de manutenção, acurácia de extração e estabilidade do formato de saída. A literatura sobre abertura de modelos, transparência e disponibilidade de pesos indica que essas decisões envolvem graus diferentes de controle, visibilidade e responsabilidade operacional (SOLAIMAN, 2023; BOMMASANI et al., 2023; National Telecommunications and Information Administration, 2024).

A arquitetura plugável proposta permite que o sistema não dependa rigidamente de um único fornecedor. Essa característica é relevante porque modelos multimodais evoluem rapidamente, custos mudam e APIs podem ser alteradas. Ao encapsular a chamada aos modelos em um *ModelAdapter*, o trabalho investiga uma forma de tornar o sistema mais substituível, testável e comparável.

Além disso, a padronização da saída em JSON e o uso de um validador de esquema contribuem para transformar uma resposta probabilística em um dado operacional que pode ser armazenado, auditado e revisado. Essa transição entre inferência de IA e dado persistente é uma questão central para a integração de IA em sistemas de informação, pois envolve confiabilidade, documentação do comportamento do modelo, auditoria e interação humana nos casos de incerteza (National Institute of Standards and Technology, 2023; RAJI et al., 2020; AMERSHI et al., 2019; MITCHELL et al., 2019).

1.4.1 Objetivo geral

O objetivo geral deste trabalho é projetar, implementar e avaliar uma arquitetura plugável para extração estruturada de respostas em provas objetivas manuscritas, comparando experimentalmente um modelo multimodal aberto hospedado em servidor próprio e um modelo multimodal proprietário acessado por API externa.

1.4.2 Objetivos específicos

Para alcançar o objetivo geral, os seguintes objetivos específicos foram delineados:

- Definir o fluxo de entrada, processamento, validação e saída para imagens de provas objetivas manuscritas capturadas por aplicativo móvel.
- Projetar uma arquitetura com aplicativo móvel, backend, *ModelAdapter*, *OpenModelProvider*, *ClosedModelProvider*, validador de JSON, banco de dados e tela de validação humana.
- Implementar um contrato padronizado de saída em JSON para representar elementos estruturais extraídos, respostas marcadas, confiança, inconsistências e necessidade de revisão humana.
- Extrair elementos estruturais de documentos manuscritos, incluindo identificação de questões, alternativas disponíveis e respostas marcadas.
- Reconhecer a identificação manuscrita do aluno quando possível.
- Tratar rasuras, ambiguidades visuais e casos de baixa confiança por meio de validação humana.
- Integrar um modelo multimodal aberto hospedado em servidor próprio e exposto como API.
- Integrar um modelo multimodal proprietário acessado por API externa.
- Permitir a configuração do provedor de IA utilizado pelo sistema, sem alterar o fluxo principal do aplicativo.
- Conduzir um experimento comparativo entre os provedores, utilizando o mesmo conjunto de provas, o mesmo esquema de saída e as mesmas métricas de avaliação.
- Analisar acurácia, taxa de JSON válido, latência, custo operacional, robustez, taxa de intervenção humana e implicações arquiteturais de cada abordagem.

1.5 Organização do trabalho

A introdução termina com a apresentação dos demais capítulos do trabalho. O capítulo 2 apresenta o referencial teórico, incluindo processamento inteligente de documentos, modelos multimodais, arquiteturas com provedores plugáveis e validação humana. O capítulo 3 descreve a metodologia adotada e o desenho experimental comparativo. O capítulo 4 apresenta o desenvolvimento do artefato, o storyboard do aplicativo, a arquitetura da solução e as métricas de avaliação. O capítulo 5 discute os resultados esperados. Por fim, a conclusão apresenta as considerações finais, as contribuições técnicas e as limitações do estudo.

Este trabalho segue as normas estabelecidas pela ABNT ([ABNT, 2011](#)), conforme orientações do modelo canônico ([ARAUJO, 2015](#)).

2 Referencial Teórico

Este capítulo apresenta os conceitos que fundamentam o trabalho sob a perspectiva de Sistemas de Informação. O foco recai sobre processamento inteligente de documentos, modelos multimodais, arquiteturas de integração com provedores de IA, validação de saídas estruturadas e avaliação experimental de artefatos computacionais.

2.1 Processamento de Documentos Manuscritos

O processamento de documentos manuscritos envolve a conversão de um artefato físico, sujeito a variações de escrita, captura, organização visual e marcação, em registros digitais que possam ser armazenados e utilizados por um sistema. Em provas objetivas manuscritas, a extração de informação exige reconhecer identificação do aluno, enunciados, numeração das questões, alternativas disponíveis, marcações de resposta, rasuras e ambiguidades visuais. A dificuldade aumenta quando a captura ocorre por fotografia, pois o sistema passa a lidar com inclinação, sombras, reflexos, baixa resolução, cortes parciais, caligrafias distintas e leiaute manuscrito irregular. O reconhecimento de manuscritos, tanto em cenários on-line quanto off-line, é um problema consolidado na área de análise de padrões e documentos ([PLAMONDON; SRIHARI, 2000](#); [RASSUL et al., 2025](#)).

Soluções tradicionais baseadas em Reconhecimento Óptico de Marcas (OMR) tendem a funcionar melhor quando há um formulário padronizado e condições controladas de digitalização. Técnicas de OCR, como o Tesseract, e abordagens recentes de OMR, incluindo modelos leves e processamento com câmeras de smartphone, mostram diferentes caminhos para digitalização de documentos e marcações ([SMITH, 2007](#); [MONDAL et al., 2024](#); [HAFEEZ et al., 2024](#)). Já abordagens baseadas em entendimento de documentos podem interpretar simultaneamente texto, leiaute e imagem, reduzindo a dependência de templates rígidos ([XU et al., 2020](#); [KIM et al., 2022](#)). Essa flexibilidade, entretanto, precisa ser avaliada empiricamente antes de ser incorporada a um sistema de informação, especialmente quando o documento é manuscrito.

2.2 Modelos Multimodais

Modelos multimodais de linguagem combinam processamento textual com interpretação visual, permitindo que uma imagem seja fornecida junto de uma instrução textual. No contexto deste trabalho, o modelo recebe a imagem da prova objetiva manuscrita e uma especificação do formato de saída esperado, retornando dados estruturados sobre questões identificadas, alternativas detectadas, respostas marcadas, identificação do aluno,

rasuras, ambiguidades visuais e grau de confiança. Tarefas como VQA em documentos, pré-treinamento com texto e leiaute, e entendimento de documentos sem OCR indicam a relevância dos modelos multimodais para esse tipo de dado visual (MATHEW; KARATZAS; JAWAHAR, 2021; XU et al., 2020; KIM et al., 2022).

Apesar do potencial técnico, a resposta de um modelo multimodal não deve ser tratada automaticamente como dado válido. Como esses modelos são probabilísticos, o sistema precisa considerar respostas incompletas, inconsistentes ou incompatíveis com o esquema esperado. Por isso, a arquitetura proposta incorpora validação de JSON, registro de incertezas e revisão humana para casos que não atendem aos critérios de qualidade.

2.3 Modelos Abertos e Modelos Proprietários

A comparação entre modelos abertos hospedados em infraestrutura própria e modelos proprietários acessados por API externa é relevante para decisões de arquitetura. Um modelo aberto pode oferecer maior controle sobre ambiente, versionamento, política de dados e execução, mas pode exigir maior capacidade de infraestrutura, configuração e manutenção. Um modelo proprietário pode simplificar a integração inicial e oferecer infraestrutura gerenciada, mas introduz dependência de fornecedor, custos por uso e menor controle sobre o funcionamento interno do serviço.

Neste trabalho, esses dois arranjos são tratados como provedores de IA diferentes. O *OpenModelProvider* representa o modelo multimodal aberto hospedado em servidor próprio e exposto como API. O *ClosedModelProvider* representa o modelo multimodal proprietário consumido por API externa. Ambos são acessados pelo backend por meio do mesmo *ModelAdapter*, o que permite comparar resultados sob o mesmo contrato de entrada e saída. Essa separação é relevante para discutir governança, dependência de fornecedores, transparência e riscos associados à adoção de sistemas baseados em IA (SOLAIMAN, 2023; BOMMASANI et al., 2023; National Telecommunications and Information Administration, 2024; National Institute of Standards and Technology, 2023).

2.4 Arquiteturas Plugáveis em Sistemas de Informação

Arquiteturas plugáveis buscam separar a regra de negócio das implementações concretas de componentes substituíveis. No caso deste trabalho, o componente substituível é o provedor de IA. A aplicação não deve depender diretamente de uma API específica, pois isso dificultaria a comparação experimental e a manutenção do sistema quando novos modelos forem testados.

A camada *ModelAdapter* funciona como fronteira técnica entre o fluxo de extração e os provedores. Ela recebe uma requisição padronizada, chama o provedor configurado,

interpreta a resposta bruta e retorna uma estrutura compatível com o esquema esperado pelo sistema. Essa separação permite alternar provedores por configuração, registrar métricas de execução e manter a mesma tela de validação humana para ambos os modelos.

2.5 Saída Estruturada e Validação Humana

Em um sistema transacional, uma resposta textual livre produzida por IA não é suficiente. O resultado precisa ser convertido em uma estrutura previsível, validada contra regras formais e persistida com rastreabilidade. Por isso, o trabalho adota uma saída em JSON contendo, no mínimo, identificador da submissão, respostas extraídas, campos de confiança, erros de validação e indicação de revisão humana.

A validação humana é tratada como parte do fluxo, e não como uma etapa externa. Quando o modelo retorna baixa confiança, resposta ausente, alternativa ambígua ou JSON inválido, o sistema apresenta o caso em uma tela de validação. A correção feita pelo usuário é armazenada junto do resultado original, permitindo comparar a saída do modelo com o resultado final validado. Essa abordagem se alinha a recomendações de interação humano-IA, auditoria algorítmica e gestão de riscos em sistemas baseados em IA ([AMERSHI et al., 2019](#); [RAJI et al., 2020](#); [National Institute of Standards and Technology, 2023](#)).

2.6 Design Science Research e Avaliação de Artefatos

A metodologia Design Science Research (DSR) é adequada para este trabalho por orientar a construção e avaliação de artefatos voltados à solução de problemas em Sistemas de Informação ([SPOSITO et al., 2024](#)). O artefato proposto não é apenas uma interface de usuário, mas uma arquitetura operacional composta por aplicativo, backend, adaptadores, provedores, banco de dados e mecanismos de validação.

A avaliação do artefato será conduzida de forma experimental e comparativa, observando métricas técnicas e operacionais. O Framework for Evaluation in Design Science (FEDS) apoia a definição de avaliações formativas e somativas ao longo do ciclo de desenvolvimento ([VENABLE; PRIES-HEJE; BASKERVILLE, 2016](#)). Neste trabalho, a avaliação final deverá indicar qual abordagem técnica se mostrou mais adequada para o problema definido, considerando não apenas acurácia, mas também custo, latência, taxa de saída válida e necessidade de intervenção humana.

2.7 Trabalhos Relacionados

Diversos trabalhos abordam a correção automática de avaliações objetivas, especialmente por meio de Reconhecimento Óptico de Marcas (OMR), processamento de imagem e captura por câmera. Fisteus, Pardo e García propuseram o Eyegrade, um sistema de baixo custo para correção de exames de múltipla escolha utilizando webcam, com o objetivo de reduzir a dependência de scanners especializados (FISTEUS; PARDO; GARCÍA, 2013). De forma semelhante, Zampirolli, Quilici-Gonzalez e Neves investigaram a correção automática de testes de múltipla escolha com câmeras digitais e processamento de imagem (ZAMPIROLI; QUILICI-GONZALEZ; NEVES, 2013), enquanto trabalhos posteriores exploraram a execução desse tipo de correção em dispositivos Android (ZAMPIROLI et al., 2015). Essas abordagens demonstram a viabilidade do uso de câmeras comuns para correção automática, mas permanecem mais próximas de cenários baseados em marcações e estruturas previamente definidas.

Também existem trabalhos voltados ao reconhecimento de marcações e ao processamento de documentos por visão computacional, como OMRNet e abordagens tolerantes a falhas para OMR com câmeras de smartphone (MONDAL et al., 2024; HAFEEZ et al., 2024). Embora essas soluções sejam relevantes para leitura de marcações, elas normalmente assumem formulários ou folhas de resposta mais estruturadas. O presente trabalho, por outro lado, considera provas objetivas manuscritas, nas quais enunciados, numeração, alternativas, identificação do aluno e marcações de resposta podem estar escritos à mão. Assim, o problema não se limita à detecção de bolhas ou campos fixos, mas envolve a extração estruturada de elementos visuais heterogêneos.

No contexto brasileiro, o sistema Minha Prova propôs a automatização do processo avaliativo escolar (SILVA, 2019), enquanto o trabalho Avalia investigou a correção automatizada de atividades escolares utilizando OCR e inteligência artificial (OLIVEIRA; SILVA, 2024). Mais recentemente, Almeida et al. apresentaram um sistema para geração e correção automática de provas utilizando IA generativa, arquitetura de microsserviços, modelos locais via Ollama, banco vetorial e RAG (ALMEIDA et al., 2025). Esses trabalhos indicam o crescimento do uso de IA em processos avaliativos, mas diferem do presente estudo por concentrarem-se na aplicação educacional, na geração de questões ou na correção automatizada em sentido amplo.

Pesquisas recentes em *document understanding* e modelos multimodais, como LayoutLM, DocVQA, Donut e DocLLM, demonstram a evolução de técnicas capazes de combinar texto, imagem e leiaute (XU et al., 2020; MATHEW; KARATZAS; JAWAHAR, 2021; KIM et al., 2022; WANG et al., 2024). Estudos sobre reconhecimento de manuscritos com LLMs multimodais também indicam o interesse recente em utilizar modelos multimodais para documentos visualmente complexos (LI, 2024). Esses trabalhos fornecem base técnica para a extração estruturada de documentos, mas não tratam especificamente

da comparação arquitetural entre provedores multimodais abertos e proprietários em um sistema de informação para provas objetivas manuscritas.

Dessa forma, a diferença central deste TCC está na proposta e avaliação de uma arquitetura plugável que permite comparar, sob o mesmo contrato de entrada e saída, um modelo multimodal aberto hospedado em servidor próprio e um modelo multimodal proprietário acessado por API externa. A contribuição não se limita ao desenvolvimento de uma aplicação de correção, mas à análise técnica da substituíbilidade de provedores, da validade da saída JSON, da necessidade de validação humana e dos trade-offs de acurácia, custo, latência, privacidade e robustez.

2.8 Síntese do Referencial

O referencial teórico sustenta que a contribuição deste trabalho está na integração entre modelos multimodais e sistemas de informação, com ênfase em arquitetura plugável, extração estruturada de documento manuscrito, padronização de saída, validação humana e avaliação comparativa. A aplicação em provas objetivas manuscritas oferece um caso concreto para medir o comportamento dos modelos em documentos físicos e visualmente heterogêneos, mas o foco da pesquisa permanece na decisão técnica entre diferentes estratégias de provisão de IA.

3 Metodologia

A condução deste trabalho segue a metodologia Design Science Research (DSR), pois o estudo envolve a construção e avaliação de um artefato técnico para um problema de Sistemas de Informação (SPOSITO et al., 2024). O artefato será avaliado por meio de um experimento comparativo entre dois arranjos de provisão de IA: um modelo multimodal aberto hospedado em infraestrutura própria e um modelo multimodal proprietário acessado por API externa.

3.1 O Ciclo DSR

O ciclo iterativo da DSR para este projeto será estruturado em cinco fases:

3.1.1 Identificação do Problema e Motivação

O problema é definido como a extração confiável de respostas em provas objetivas manuscritas a partir de imagens capturadas por dispositivo móvel. A motivação técnica está na necessidade de comparar provedores multimodais diferentes sob uma mesma arquitetura, evitando que o sistema fique dependente de um único modelo ou fornecedor.

3.1.2 Definição dos Objetivos da Solução

A solução deverá permitir captura da imagem, envio ao backend, seleção do provedor de IA, extração multimodal, validação de JSON, persistência e revisão humana. O objetivo da avaliação será comparar as abordagens técnica e operacionalmente, usando o mesmo conjunto de provas e o mesmo esquema de saída.

3.1.3 Design e Desenvolvimento

O artefato será composto por aplicativo móvel, backend, banco de dados, *ModelAdapter*, *OpenModelProvider*, *ClosedModelProvider*, validador de JSON e tela de validação humana. O aplicativo móvel não executará modelos localmente; ele apenas capturará imagens e exibirá resultados. O backend será responsável por orquestrar o fluxo e registrar métricas de execução.

3.1.4 Demonstração e Avaliação

O protótipo será avaliado com lotes de provas objetivas manuscritas. Cada imagem será processada pelos dois provedores, preservando as mesmas condições de entrada. O re-

sultado de cada modelo será comparado com um padrão-ouro definido por validação manual. A avaliação seguirá uma abordagem formativa durante o desenvolvimento e uma avaliação somativa ao final, alinhada ao FEDS ([VENABLE](#); [PRIES-HEJE](#); [BASKERVILLE, 2016](#)).

3.1.5 Comunicação

Os resultados serão comunicados por meio da descrição da arquitetura, do fluxo implementado, das métricas coletadas e da análise comparativa entre o modelo aberto e o modelo proprietário. A conclusão deverá indicar qual abordagem foi mais adequada para o cenário estudado e sob quais critérios.

3.2 Procedimentos Metodológicos

Os procedimentos metodológicos adotados incluem:

- **Revisão bibliográfica:** análise de literatura sobre processamento inteligente de documentos, modelos multimodais, arquitetura de sistemas com IA e avaliação de artefatos.
- **Prototipagem iterativa:** desenvolvimento incremental do aplicativo, backend e provedores, com testes de integração a cada ciclo.
- **Definição do padrão-ouro:** validação manual das respostas presentes nas provas para estabelecer a referência de comparação.
- **Experimentação comparativa:** processamento do mesmo conjunto de imagens pelo modelo aberto e pelo modelo proprietário.
- **Análise de métricas:** coleta de acurácia, taxa de JSON válido, latência, custo estimado, robustez, taxa de intervenção humana e erros associados a caligrafia, leiaute manuscrito irregular, rasuras e marcações ambíguas.
- **Análise arquitetural:** discussão dos impactos de infraestrutura, manutenção, privacidade, dependência de fornecedor e substituição de modelos.

4 Desenvolvimento e Experimento

Este capítulo descreve o storyboard do aplicativo, a arquitetura proposta, o fluxo de extração e o desenho experimental usado para comparar os provedores multimodais.

4.1 Storyboard do Aplicativo

O storyboard descreve o fluxo de interação do usuário com o sistema e explicita entradas, processamento e saídas. A entrada é uma prova objetiva manuscrita completa, e não apenas um formulário impresso com campos de resposta marcados. O aplicativo móvel atua como interface de captura e visualização, enquanto o processamento de IA ocorre no backend e nos provedores externos ao dispositivo.

4.1.1 Entradas

As entradas principais do sistema são:

- imagem de uma prova objetiva manuscrita capturada por smartphone;
- metadados da turma, prova ou lote de processamento;
- provedor de IA selecionado: modelo aberto em servidor próprio ou modelo proprietário via API externa.

4.1.2 Processamento

Após a captura, o aplicativo envia a imagem ao backend. O backend registra a submissão, aplica validações iniciais, seleciona o provedor configurado e aciona o *ModelAdapter*. A requisição é processada pelo modelo aberto ou pelo modelo proprietário, conforme a configuração. O modelo deve extrair os elementos estruturais da prova, incluindo identificação do aluno, questões, alternativas disponíveis, resposta marcada, rasuras e ambiguidades visuais. A resposta bruta é normalizada para o JSON padronizado. Em seguida, o validador realiza validação estrutural e semântica, verificando campos obrigatórios, tipos de dados, consistência entre questões e alternativas, níveis de confiança e inconsistências.

Quando a resposta é válida e possui confiança suficiente, o resultado é persistido no banco de dados. Quando há baixa confiança, rasura, ambiguidade visual ou JSON inválido, o item é direcionado para a tela de validação humana.

4.1.3 Saídas

As saídas do sistema são:

- identificação do aluno, quando reconhecida;
- questões identificadas;
- alternativas detectadas;
- respostas extraídas;
- indicação de confiança por item ou por prova;
- lista de inconsistências que exigem revisão;
- resultado final validado;
- métricas de execução usadas no experimento comparativo.

4.1.4 Componentes

Os componentes principais são:

- **App móvel:** captura imagens de provas objetivas manuscritas, permite selecionar ou visualizar o provedor configurado, envia provas ao backend e apresenta os resultados.
- **Backend:** recebe as imagens, cria registros de submissão, coordena o fluxo, chama o adaptador de modelos, persiste resultados e disponibiliza APIs para consulta.
- **ModelAdapter:** define uma interface comum para todos os provedores de IA, encapsulando diferenças de autenticação, payload, prompt, resposta e tratamento de erro.
- **OpenModelProvider:** chama o modelo multimodal aberto hospedado em servidor próprio e exposto como API interna ou controlada pelo projeto.
- **ClosedModelProvider:** chama o modelo multimodal proprietário acessado por API externa.
- **Validador de JSON:** verifica se a resposta do provedor segue o esquema padronizado e identifica inconsistências estruturais e semânticas.
- **Banco de dados:** armazena imagens ou referências às imagens, respostas brutas, respostas normalizadas, métricas, status de validação e resultado final.
- **Tela de validação humana:** apresenta casos ambíguos ou inválidos para correção manual e registra a decisão final.

4.1.5 Fluxo de Extração

O fluxo de extração será composto pelas seguintes etapas:

1. captura da imagem de uma prova objetiva manuscrita pelo aplicativo móvel;
2. envio da imagem e dos metadados ao backend;
3. seleção do provedor de IA conforme configuração;
4. preparação da requisição padronizada pelo *ModelAdapter*;
5. execução da inferência pelo *OpenModelProvider* ou *ClosedModelProvider*;
6. extração dos elementos estruturais da prova;
7. normalização da resposta bruta para o esquema JSON do sistema;
8. validação estrutural e semântica do JSON;
9. persistência do resultado e das métricas;
10. encaminhamento para validação humana quando necessário;
11. consolidação do resultado final para visualização no aplicativo.

4.1.6 Contrato de Saída

O contrato de saída deverá conter uma estrutura semelhante à apresentada no Código 1. O exemplo é ilustrativo e será refinado durante a implementação.

```
1 {  
2   "submission_id": "sub-001",  
3   "student_identifier": "nome reconhecido ou null",  
4   "questions": [  
5     {  
6       "question": 1,  
7       "detected_alternatives": ["A", "B", "C", "D"],  
8       "selected_option": "A",  
9       "confidence": 0.91,  
10      "visual_ambiguities": [],  
11      "requires_human_review": false  
12    }  
13  ],  
14  "overall_confidence": 0.88,  
15  "validation_errors": []  
16 }
```

Código 1 – Exemplo de saída padronizada em JSON

4.2 Experimento Comparativo

O experimento tem como finalidade comparar o desempenho técnico e operacional do modelo aberto hospedado em servidor próprio e do modelo proprietário via API externa.

4.2.1 Desenho Experimental

O experimento será realizado em três etapas:

1. **Preparação do conjunto de testes:** seleção ou produção de provas objetivas manuscritas, com variações de caligrafia, leiaute, iluminação, enquadramento, marcações e rasuras.
2. **Construção do padrão-ouro:** leitura manual das provas para registrar a resposta correta de cada questão e os casos ambíguos.
3. **Processamento comparativo:** envio das mesmas imagens aos dois provedores, usando o mesmo prompt-base, o mesmo esquema JSON e as mesmas métricas.

4.2.2 Cenários Avaliados

Serão considerados, no mínimo, os seguintes cenários:

- provas com enunciados, numeração e alternativas manuscritas;
- provas com marcações de resposta claras;
- provas com marcações fracas ou incompletas;
- provas com rasuras;
- provas com leiaute manuscrito irregular;
- imagens com inclinação;
- imagens com sombras ou baixa iluminação;
- campos de identificação manuscritos.

4.2.3 Métricas de Avaliação

A avaliação do artefato será quantitativa e qualitativa, focando nas seguintes dimensões:

- **Acurácia de identificação das questões:** proporção de questões reconhecidas corretamente em relação ao padrão-ouro.

- **Acurácia de identificação das alternativas:** proporção de alternativas disponíveis detectadas corretamente.
- **Acurácia de extração da resposta marcada:** proporção de respostas escolhidas identificadas corretamente.
- **Acurácia de reconhecimento da identificação manuscrita:** proporção de identificações de alunos reconhecidas corretamente quando houver campo legível.
- **Acurácia por prova:** proporção de provas com todos os elementos estruturais necessários extraídos corretamente.
- **Taxa de JSON válido:** proporção de respostas que atendem ao esquema definido sem reparo manual.
- **Latência:** tempo entre envio da imagem e retorno da resposta normalizada.
- **Custo operacional:** custo estimado por prova processada em cada provedor.
- **Taxa de erro por caligrafia ilegível:** proporção de erros associados à impossibilidade de leitura do texto manuscrito.
- **Taxa de erro por leiaute manuscrito irregular:** proporção de erros associados à organização visual da prova.
- **Taxa de casos enviados para validação humana:** proporção de provas ou questões encaminhadas para revisão.
- **Tipos de erro:** classificação dos erros por marcação ambígua, rasura, campo ausente, questão não identificada, alternativa incorreta, identificação manuscrita incorreta, JSON inválido ou falha de provedor.

4.2.4 Tabela Comparativa Planejada

Os resultados serão organizados conforme a Tabela 1. Os valores serão preenchidos após a execução do experimento.

4.2.5 Critério de Análise

O modelo tecnicamente mais adequado não será definido apenas pela maior acurácia. A análise considerará o equilíbrio entre qualidade da extração estruturada, validade da saída JSON, custo, latência, robustez frente a manuscritos e leiautes irregulares, controle operacional, privacidade, facilidade de manutenção e quantidade de revisão humana necessária.

Tabela 1 – Comparação experimental entre provedores multimodais

Métrica	Modelo aberto em servidor próprio	Modelo proprietário via API externa
Acurácia de questões	A preencher	A preencher
Acurácia de alternativas	A preencher	A preencher
Acurácia de respostas	A preencher	A preencher
Identificação manuscrita	A preencher	A preencher
Taxa de JSON válido	A preencher	A preencher
Latência média	A preencher	A preencher
Custo por prova	A preencher	A preencher
Validação humana	A preencher	A preencher
Erros por caligrafia	A preencher	A preencher
Erros por leiaute	A preencher	A preencher
Falhas de provedor	A preencher	A preencher
Observações arquiteturais	A preencher	A preencher

4.3 Cronograma de Execução do Experimento

O experimento será planejado em quatro etapas:

- **Etapa 1:** preparação das provas, definição do esquema JSON e implementação dos provedores.
- **Etapa 2:** criação do padrão-ouro manual e configuração do ambiente do modelo aberto.
- **Etapa 3:** execução dos testes com ambos os provedores e coleta das métricas.
- **Etapa 4:** análise dos resultados, classificação dos erros e discussão arquitetural.

5 Expectativas de Conclusão e Resultados Esperados

Ao final deste trabalho, espera-se entregar um artefato funcional e uma avaliação comparativa fundamentada sobre duas estratégias de uso de modelos multimodais para extração estruturada de informações em provas objetivas manuscritas.

5.1 Contribuição Científica e Prática

A contribuição esperada é demonstrar como uma arquitetura plugável permite avaliar provedores de IA sob condições equivalentes, mantendo o restante do sistema estável. Espera-se também identificar limitações práticas de cada abordagem, especialmente em relação à extração estruturada de documento manuscrito, confiabilidade da saída JSON, custo de operação, controle sobre infraestrutura, robustez e necessidade de validação humana.

O resultado final deverá indicar qual abordagem foi mais adequada ao cenário avaliado. Caso o modelo aberto apresente acurácia suficiente e custos menores, a infraestrutura própria poderá ser considerada vantajosa apesar da complexidade operacional. Caso o modelo proprietário apresente maior estabilidade, menor latência ou menor taxa de intervenção humana, a API externa poderá ser mais adequada mesmo com dependência de fornecedor. Também é possível que os resultados apontem para uma estratégia híbrida, na qual cada provedor seja usado em cenários distintos.

5.2 Resultados Esperados

Os resultados esperados são:

- definição de um fluxo reprodutível para extração estruturada de informações em provas objetivas manuscritas;
- implementação de uma arquitetura com provedores de IA substituíveis por configuração;
- comparação quantitativa entre modelo aberto e modelo proprietário;
- identificação dos principais tipos de erro na extração multimodal de elementos manuscritos;

- avaliação da utilidade do validador de JSON e da tela de validação humana;
- discussão sobre qual abordagem técnica se mostrou mais adequada para o sistema proposto.

5.3 Limites da Conclusão Esperada

Não se pretende concluir genericamente que modelos multimodais substituem métodos tradicionais em todos os contextos. A conclusão deverá se restringir ao conjunto de provas, modelos, infraestrutura, prompts, métricas e condições experimentais definidos neste trabalho. Generalizações dependerão de novos experimentos com outros formatos de prova, outros modelos e maior diversidade de condições de captura.

6 Conclusão

Este trabalho propõe o desenvolvimento e a avaliação de uma arquitetura plugável para extração estruturada de informações em provas objetivas manuscritas. O foco da pesquisa está na comparação entre dois arranjos técnicos de uso de modelos multimodais: um modelo aberto hospedado em servidor próprio e exposto como API, e um modelo proprietário acessado por API externa. O aplicativo móvel é tratado como interface de captura e visualização, não como ambiente de execução dos modelos.

6.1 Síntese dos Resultados Esperados

Espera-se que o artefato permita comparar os provedores sob o mesmo fluxo de entrada, processamento, validação e saída. A análise deverá considerar acurácia de identificação de questões, alternativas, respostas marcadas e identificação manuscrita do aluno, além de taxa de JSON válido, latência, custo operacional, robustez, taxa de intervenção humana, estabilidade da integração e implicações arquiteturais. Assim, a conclusão esperada não será apenas a afirmação de que o sistema foi construído, mas a identificação fundamentada da abordagem técnica mais adequada ao cenário estudado.

O resultado poderá favorecer o modelo aberto, o modelo proprietário ou uma estratégia híbrida. Essa decisão dependerá dos dados coletados no experimento. Por exemplo, um modelo aberto pode ser mais adequado quando controle de infraestrutura, custo recorrente e privacidade forem prioritários. Um modelo proprietário pode ser mais adequado quando estabilidade operacional, menor esforço de manutenção ou maior acurácia forem predominantes. Os critérios de avaliação serão definidos considerando gestão de riscos em IA, qualidade de sistemas e princípios de avaliação de artefatos em Design Science Research ([National Institute of Standards and Technology, 2023](#); [International Organization for Standardization, 2011](#); [HEVNER et al., 2004](#); [PEFFERS et al., 2007](#)).

6.2 Considerações sobre Ética, Privacidade e Controle

A extração automatizada de informações em provas objetivas manuscritas envolve dados pessoais e registros acadêmicos. Por isso, a arquitetura deverá considerar privacidade, segurança, rastreabilidade e controle humano. O uso de um provedor proprietário via API externa exige atenção ao envio de imagens e metadados para terceiros. O uso de um modelo aberto em servidor próprio reduz parte dessa dependência, mas transfere para o mantenedor do sistema a responsabilidade pela segurança da infraestrutura.

O sistema deverá garantir que:

- imagens e resultados sejam armazenados com controle de acesso;
- respostas brutas dos modelos sejam registradas para auditoria;
- dados pessoais sejam tratados conforme princípios da LGPD;
- casos ambíguos sejam encaminhados para validação humana;
- a decisão final validada possa ser rastreada em relação à saída original do modelo.

Essas preocupações estão relacionadas à proteção de dados pessoais, aos papéis dos agentes de tratamento, à gestão de riscos em IA e à auditoria de sistemas algorítmicos (Brasil, 2018; Autoridade Nacional de Proteção de Dados, 2024; National Institute of Standards and Technology, 2023; RAJI et al., 2020).

6.3 Contribuições Esperadas

Este trabalho pretende contribuir para Sistemas de Informação em múltiplas dimensões:

6.3.1 Contribuição Científica

- avaliação empírica de modelos multimodais em uma tarefa de extração de dados visuais estruturados a partir de provas objetivas manuscritas;
- comparação entre modelo aberto hospedado em servidor próprio e modelo proprietário via API externa;
- análise do papel de contratos de saída JSON, validação estrutural e semântica e validação humana em sistemas com IA;
- aplicação da DSR no desenvolvimento e avaliação de um artefato de integração entre aplicativo, backend e provedores de IA.

6.3.2 Contribuição Técnica

- arquitetura plugável com *ModelAdapter*, *OpenModelProvider* e *ClosedModelProvider*;
- Fluxo de extração estruturada de documento manuscrito com normalização de resposta e validação de esquema;
- tela de validação humana integrada ao fluxo de persistência;

- conjunto de métricas para comparar acurácia, latência, custo, robustez e intervenção humana entre provedores multimodais;
- base para substituição futura de modelos sem reescrever o aplicativo móvel ou o backend.

6.4 Limitações do Estudo

É importante reconhecer as limitações previstas para este trabalho:

- O escopo é limitado a provas objetivas manuscritas, não contemplando correção semântica de questões dissertativas.
- O conjunto de provas utilizado no experimento poderá não representar todos os formatos e condições de captura existentes.
- A comparação dependerá dos modelos selecionados e de suas versões no momento do experimento.
- O modelo aberto exigirá infraestrutura própria, o que pode influenciar latência, custo e disponibilidade.
- O modelo proprietário estará sujeito às condições, limites e custos definidos pelo fornecedor da API.
- Casos com caligrafia ilegível, marcações extremamente ambíguas, imagens degradadas ou campos ausentes ainda poderão exigir intervenção humana.

6.5 Trabalhos Futuros

Vislumbra-se a expansão do sistema em várias direções:

6.5.1 Ampliação dos Modelos Avaliados

Trabalhos futuros podem incluir mais modelos abertos e proprietários, bem como diferentes versões do mesmo modelo. Essa ampliação permitiria verificar se os resultados observados decorrem da categoria do provedor ou de características específicas dos modelos escolhidos.

6.5.2 Avaliação com Diferentes Formatos de Documento

Outra possibilidade é aplicar o mesmo fluxo a outros documentos manuscritos, como formulários administrativos, listas de presença ou questionários de pesquisa. Isso

ajudaria a avaliar a generalidade da arquitetura fora do contexto de provas objetivas manuscritas.

6.5.3 Otimização do Fluxo

O Fluxo poderá ser otimizado com pré-processamento de imagem, compressão controlada, detecção automática de baixa qualidade, filas assíncronas e estratégias de repetição quando o provedor retornar erro ou JSON inválido.

6.5.4 Expansão da Validação Humana

A tela de validação humana poderá evoluir para registrar motivos de correção, comparar sugestões de diferentes modelos e permitir que o usuário visualize a região da imagem associada a cada resposta extraída.

6.5.5 Integração com Sistemas Externos

O sistema poderá ser integrado a ambientes acadêmicos ou administrativos já existentes, desde que o contrato de saída e as regras de privacidade sejam preservados. Essa etapa exigiria conectores específicos e avaliação adicional de segurança.

6.5.6 Modelo Híbrido de Provedores

Uma extensão natural é investigar uma estratégia híbrida, usando o modelo aberto para casos simples e o modelo proprietário para casos ambíguos, ou o inverso. Essa abordagem permitiria otimizar custo, latência e acurácia conforme o tipo de entrada.

6.6 Considerações Finais

Este TCC busca contribuir tecnicamente para a integração de modelos multimodais em Sistemas de Informação, tratando a IA como componente substituível, mensurável e sujeito a validação. A avaliação comparativa proposta deverá permitir uma conclusão mais precisa sobre quando utilizar infraestrutura própria com modelo aberto e quando utilizar uma API proprietária externa em tarefas de extração estruturada de documentos manuscritos.

A relevância do trabalho está em deslocar a discussão do simples desenvolvimento de um aplicativo para a análise de uma arquitetura capaz de receber documentos físicos manuscritos, acionar diferentes provedores de IA, validar saídas estruturadas, registrar decisões e apoiar uma comparação experimental. Com isso, espera-se produzir uma contribuição técnica alinhada à área de Sistemas de Informação e útil para projetos que dependam da transformação de imagens de documentos manuscritos em dados operacionais.

Referências

- ALMEIDA, D. et al. Estudo e desenvolvimento de um sistema para geração e correção automática de provas utilizando inteligência artificial. In: *Anais do Seminário de Iniciação Científica e Tecnológica do IFG*. [S.l.: s.n.], 2025. v. 18, n. 1.
- AMERSHI, S. et al. Guidelines for human-ai interaction. In: *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. [S.l.: s.n.], 2019. p. 1–13.
- ARAUJO, L. C. *Modelo Canônico de Trabalho Acadêmico com abnTeX2*. [S.l.], 2015. Disponível em: <<http://www.abntex.net.br/>>.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 14724: Informação e documentação — trabalhos acadêmicos — apresentação*. Rio de Janeiro, 2011. 15 p.
- Autoridade Nacional de Proteção de Dados. *Guia orientativo para definições dos agentes de tratamento de dados pessoais e do encarregado*. 2024. Acesso em: 7 jun. 2026. Disponível em: <<https://www.gov.br/anpd/>>.
- BOMMASANI, R. et al. The foundation model transparency index. *arXiv preprint arXiv:2310.12941*, 2023. Disponível em: <<https://arxiv.org/abs/2310.12941>>.
- Brasil. *Lei nº 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais*. 2018. Acesso em: 7 jun. 2026. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/L13709compilado.htm>.
- FISTEUS, J. A.; PARDO, A.; GARCÍA, N. F. Grading multiple choice exams with low-cost and portable computer-vision techniques. *Journal of Science Education and Technology*, v. 22, n. 4, p. 560–571, 2013.
- HAFEEZ, Q. et al. An enhanced fault tolerance algorithm for optical mark recognition using smartphone cameras. *IEEE Access*, v. 12, p. 121305–121319, 2024.
- HEVNER, A. R. et al. Design science in information systems research. *MIS Quarterly*, v. 28, n. 1, p. 75–105, 2004.
- International Organization for Standardization. *ISO/IEC 25010:2011 Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – System and software quality models*. 2011. Acesso em: 7 jun. 2026. Disponível em: <<https://www.iso.org/standard/35733.html>>.
- KIM, G. et al. Ocr-free document understanding transformer. In: *European Conference on Computer Vision*. [S.l.: s.n.], 2022. p. 498–517.
- LI, L. Handwriting recognition in historical documents with multimodal llm. *arXiv preprint arXiv:2410.24034*, 2024. Disponível em: <<https://arxiv.org/abs/2410.24034>>.
- MATHEW, M.; KARATZAS, D.; JAWAHAR, C. V. Docvqa: A dataset for vqa on document images. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. [s.n.], 2021. p. 2200–2209. Disponível em: <<https://arxiv.org/abs/2007.00398>>.
- MITCHELL, M. et al. Model cards for model reporting. In: *Proceedings of the Conference on Fairness, Accountability, and Transparency*. [S.l.: s.n.], 2019. p. 220–229.

- MONDAL, S. et al. Omrnet: A lightweight deep learning model for optical mark recognition. *Multimedia Tools and Applications*, v. 83, p. 14011–14045, 2024.
- National Institute of Standards and Technology. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. [S.l.], 2023. Disponível em: <<https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf>>.
- National Telecommunications and Information Administration. *Dual-Use Foundation Models with Widely Available Model Weights: Report to the President*. [S.l.], 2024. Disponível em: <<https://www.ntia.gov/sites/default/files/publications/ntia-ai-open-model-report.pdf>>.
- OLIVEIRA, A. P. d.; SILVA, G. S. V. d. *Avalia: sistema de correção automatizada de atividades escolares utilizando reconhecimento óptico de caracteres e inteligência artificial*. Monografia (Trabalho de Conclusão de Curso) — Universidade Estadual Paulista, Bauru, 2024. Disponível em: <<https://repositorio.unesp.br/server/api/core/bitstreams/45e3e419-5bd7-4b02-9f93-580883012154/content>>.
- PEFFERS, K. et al. A design science research methodology for information systems research. *Journal of Management Information Systems*, v. 24, n. 3, p. 45–77, 2007.
- PLAMONDON, R.; SRIHARI, S. N. On-line and off-line handwriting recognition: a comprehensive survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 22, n. 1, p. 63–84, 2000.
- RAJI, I. D. et al. Closing the ai accountability gap: Defining an end-to-end framework for internal algorithmic auditing. In: *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. [S.l.: s.n.], 2020. p. 33–44.
- RASSUL, Y. H. et al. Advancing offline handwritten text recognition: A systematic review of data augmentation and generation techniques. *arXiv preprint arXiv:2507.06275*, 2025. Disponível em: <<https://arxiv.org/abs/2507.06275>>.
- SILVA, T. d. S. *Minha Prova: Automatizando o processo avaliativo nas escolas*. Monografia (Trabalho de Conclusão de Curso) — Universidade Federal Rural de Pernambuco, Recife, 2019.
- SMITH, R. An overview of the tesseract ocr engine. In: *Proceedings of the Ninth International Conference on Document Analysis and Recognition*. [S.l.: s.n.], 2007. v. 2, p. 629–633.
- SOLAIMAN, I. The gradient of generative ai release: Methods and considerations. In: *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency*. [s.n.], 2023. Disponível em: <<https://arxiv.org/abs/2302.04844>>.
- SPOSITO, L. et al. Design science research: um estudo sobre o ensino do método. *Revista Ciências Administrativas*, v. 30, p. 1–18, 2024.
- VENABLE, J.; PRIES-HEJE, J.; BASKERVILLE, R. Feds: a framework for evaluation in design science research. *European journal of information systems*, Taylor & Francis, v. 25, n. 1, p. 77–89, 2016.
- WANG, D. et al. Docllm: A layout-aware generative language model for multimodal document understanding. *arXiv preprint arXiv:2401.00908*, 2024. Disponível em: <<https://arxiv.org/abs/2401.00908>>.
- XU, Y. et al. Layoutlm: Pre-training of text and layout for document image understanding. In: *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2020. p. 1192–1200.

ZAMPIROLI, F. d. A. et al. Automatic correction of multiple-choice tests on android devices. In: *Workshop de Visão Computacional*. São Carlos, Brasil: [s.n.], 2015.

ZAMPIROLI, F. d. A.; QUILICI-GONZALEZ, J. A.; NEVES, R. P. d. O. Automatic correction of multiple-choice tests using digital cameras and image processing. In: *Workshop de Visão Computacional*. Rio de Janeiro, Brasil: [s.n.], 2013.