

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais
Abertos e Proprietários para Extração de
Respostas em Provas Objetivas Manuscritas.**

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais Abertos
e Proprietários para Extração de Respostas em Provas
Objetivas Manuscritas.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Instituto Federal Catarinense – IFC

Câmpus Araquari

Sistemas de Informação

Orientador: Prof. Dr. Fabio Longo de Moura

Coorientador: Prof. Dr. Paulo Cesar Fernandes de Oliveira

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

Avaliação Comparativa de Modelos Multimodais Abertos e Proprietários para Extração de Respostas em Provas Objetivas Manuscritas. / Gabriel Lopes Pereira.
– Araquari – SC, Abril de 2026-
25 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Fabio Longo de Moura

Monografia (Graduação) – Instituto Federal Catarinense – IFC
Câmpus Araquari
Sistemas de Informação, Abril de 2026.

1. Inteligência Artificial. 2. Modelos Multimodais. 3. Sistemas de Informação.
4. Processamento de Documentos. I. Gabriel Pereira. II. Instituto Federal Catarinense. III. Câmpus Araquari. IV. Avaliação Comparativa de Modelos Multimodais Abertos e Proprietários para Extração de Respostas em Provas Objetivas Manuscritas.

Gabriel Lopes Pereira

**Avaliação Comparativa de Modelos Multimodais Abertos
e Proprietários para Extração de Respostas em Provas
Objetivas Manuscritas.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Araquari – SC
Abril de 2026

“Aquele que não tem paciência com as pequenas coisas, falhará nos grandes planos.”
- Confúcio

Resumo

Este trabalho propõe a avaliação comparativa de modelos multimodais aplicados à extração estruturada de informações em provas objetivas manuscritas. O foco está na área de Sistemas de Informação, considerando a construção de um fluxo padronizado para captura, envio, processamento, validação e análise das respostas produzidas por modelos multimodais. O aplicativo móvel não executa modelos localmente; sua função é capturar imagens e apresentar resultados. O processamento ocorre no backend, que envia as mesmas imagens para um modelo multimodal aberto e um modelo multimodal proprietário ambos acessados via API. A metodologia adota Design Science Research para orientar o desenvolvimento do artefato e um experimento comparativo para avaliar acurácia, validade da saída estruturada, latência, custo operacional, robustez e necessidade de intervenção humana. Espera-se que o resultado indique qual abordagem técnica é mais adequada ao cenário estudado, considerando o desempenho dos modelos, a confiabilidade da saída JSON e os trade-offs envolvidos na integração de modelos multimodais a sistemas de informação.

Palavras-chave: Modelos multimodais. Sistemas de Informação. Processamento de documentos. JSON. Validação humana.

Lista de abreviaturas e siglas

ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface (Interface de Programação de Aplicações)
DSR	Design Science Research
FEDS	Framework for Evaluation in Design Science
GPT	Generative Pre-trained Transformer
IA	Inteligência Artificial
IDP	Intelligent Document Processing (Processamento Inteligente de Documentos)
IFG	Instituto Federal de Goiás
JSON	JavaScript Object Notation
LGPD	Lei Geral de Proteção de Dados
LLM	Large Language Model (Modelo de Linguagem de Grande Escala)
MLLM	Multimodal Large Language Model (Modelo de Linguagem de Grande Escala Multimodal)
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)
OMR	Optical Mark Recognition (Reconhecimento Óptico de Marcas)
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
SIGAA	Sistema Integrado de Gestão de Atividades Acadêmicas
SUS	System Usability Scale (Escala de Usabilidade de Sistema)
TCC	Trabalho de Conclusão de Curso
USP	Universidade de São Paulo

Sumário

1	INTRODUÇÃO	8
1.1	Contextualização	8
1.2	Tema e Delimitação	8
1.3	Problema	9
1.4	Justificativa	10
1.5	Objetivos	11
1.5.1	Objetivo geral	11
1.5.2	Objetivos específicos	11
2	REFERENCIAL TEÓRICO	12
2.1	Processamento de Documentos Manuscritos	12
2.2	Modelos Multimodais	12
2.3	Modelos Abertos e Modelos Proprietários	13
2.4	Padronização de Entrada e Saída para Comparação de Modelos	13
2.5	Saída Estruturada e Validação Humana	14
2.6	Design Science Research e Avaliação de Artefatos	14
2.7	Trabalhos Relacionados	15
2.8	Síntese do Referencial	16
3	METODOLOGIA	17
3.1	Procedimentos Metodológicos	17
3.2	Recursos Necessários	17
3.3	Desenho do Experimento	18
3.4	Métricas de Avaliação	18
4	FLUXO EXPERIMENTAL E COMPARAÇÃO DOS MODELOS	20
4.1	Componentes do Fluxo	20
4.2	Contrato de Saída	20
4.3	Tabela Comparativa Planejada	21
5	EXPECTATIVA DE CONCLUSÃO	22
6	CONCLUSÃO	23
	REFERÊNCIAS	24

1 Introdução

1.1 Contextualização

O processamento de documentos manuscritos continua sendo um problema relevante para Sistemas de Informação, especialmente quando a entrada é capturada em papel, por câmera de dispositivo móvel, e precisa ser transformada em dados estruturados confiáveis.

O desafio técnico, portanto, não é apenas detectar marcações em um formulário impresso. A proposta envolve extrair dados estruturados de um documento manuscrito, no qual a informação de interesse pode aparecer em textos escritos à mão, marcações de resposta, rasuras, campos de identificação, leiautes irregulares e variações de iluminação, enquadramento e qualidade da imagem. Esse cenário torna o problema diferente de uma simples digitalização, pois exige um fluxo capaz de receber uma imagem não padronizada, identificar elementos estruturais, representar o resultado em formato computável e permitir validação humana quando houver incerteza.

Modelos voltados ao entendimento de documentos visuais passaram a combinar informação textual, visual e de leiaute para tarefas como extração de informação e resposta visual sobre documentos. Trabalhos como LayoutLM, DocVQA e Donut evidenciam a relevância desse campo para documentos visualmente ricos e não estruturados (XU et al., 2020; MATHEW; KARATZAS; JAWAHAR, 2021; KIM et al., 2022). Entretanto, a adoção desses modelos em sistemas reais envolve decisões técnicas que não se limitam à escolha do modelo com maior acurácia. Em um sistema de informação, também importam custo, latência, privacidade, possibilidade de auditoria, padronização de saída, tratamento de erros, integração com banco de dados e desenho de fluxos de validação.

Neste trabalho, o aplicativo móvel não executa modelos de IA localmente. Sua função é capturar a imagem da prova objetiva manuscrita, enviar a imagem ao backend e apresentar os resultados ao usuário. O processamento de IA ocorre fora do dispositivo móvel, por meio de dois tipos de modelos acessados como serviço: um modelo multimodal aberto e um modelo multimodal proprietário ambos disponibilizados via API. A contribuição técnica está na avaliação comparativa desses modelos sob um fluxo padronizado de entrada, saída, validação e mensuração.

1.2 Tema e Delimitação

O tema central deste Trabalho de Conclusão de Curso (TCC) é a avaliação comparativa de modelos multimodais aplicados à extração estruturada de informações em

provas objetivas manuscritas. O trabalho está delimitado à construção e avaliação de um sistema de informação composto por aplicativo móvel, backend, camada de integração com modelos, APIs de modelos multimodais, validador de saída estruturada, banco de dados e interface de validação humana.

O escopo contempla provas objetivas em papel, redigidas manualmente, nas quais enunciados, alternativas, identificação do aluno e marcações de resposta podem estar escritos à mão. Embora a prova seja manuscrita, o trabalho não busca corrigir semanticamente questões dissertativas. O foco permanece em avaliações objetivas, nas quais o sistema deve identificar elementos estruturais, como número da questão, alternativas disponíveis, alternativa escolhida, identificação do aluno, rasuras e ambiguidades visuais. Geração automática de provas, recomendação pedagógica e análise subjetiva de respostas ficam fora do escopo. A avaliação não tem como foco demonstrar que um aplicativo foi desenvolvido, mas verificar como modelos multimodais com diferentes graus de abertura se comportam na extração estruturada de informações quando acessados por APIs.

O escopo técnico define o uso de três pilares fundamentais:

1. **Aplicativo móvel:** interface para captura das imagens das provas, seleção do provedor de IA e visualização dos resultados retornados pelo backend.
2. **Backend e orquestração:** serviço responsável por autenticação, armazenamento, acionamento do fluxo de extração, persistência dos resultados e exposição de APIs para o aplicativo.
3. **Camada de integração com modelos:** componente *ModelAdapter* que normaliza a comunicação com um *OpenModelProvider*, acessado por API, e um *ClosedModelProvider*, também acessado por API.

O sistema deverá produzir uma saída padronizada, em JSON, contendo identificação da prova, identificação do aluno quando disponível, questões identificadas, alternativas detectadas, respostas extraídas, nível de confiança, rasuras ou ambiguidades visuais e itens que exigem validação humana. Essa padronização permite comparar modelos diferentes sob o mesmo contrato de dados e evita que cada API imponha diretamente seu formato de resposta ao restante do sistema.

1.3 Problema

O problema de pesquisa deste trabalho pode ser formulado da seguinte maneira: como modelos multimodais abertos e proprietários, acessados por APIs, diferem na extração estruturada de informações em provas objetivas manuscritas, considerando acurácia, validade da saída JSON, latência, custo, robustez e necessidade de validação humana?

A questão central não é apenas automatizar uma atividade de correção, mas investigar como diferentes estratégias de provisão de IA afetam um sistema que precisa transformar imagens de documentos físicos em registros estruturados. As imagens das provas podem conter sombras, inclinação, baixa resolução, enunciados escritos à mão, alternativas manuscritas, marcações ambíguas e rasuras. O sistema, portanto, precisa extrair elementos estruturais sem assumir que a captura ocorreu em condições ideais ou que o documento segue um formulário rígido.

Além da extração visual, o problema envolve comparabilidade entre provedores e confiabilidade da saída. Modelos abertos e proprietários podem retornar respostas em formatos distintos, com custos, latências, controles e limitações diferentes. Por isso, a comparação exige um contrato comum de entrada e saída, validação do JSON produzido e encaminhamento de casos ambíguos para revisão humana.

1.4 Justificativa

A justificativa deste trabalho está na necessidade de compreender como modelos multimodais podem ser integrados a sistemas de informação que processam documentos físicos manuscritos. Embora a aplicação escolhida esteja situada no contexto de provas objetivas, a contribuição principal não é pedagógica. O foco está na avaliação comparativa dos modelos, na extração estruturada de elementos visuais manuscritos, na normalização de dados gerados por IA, na validação de resultados e na mensuração técnica do comportamento de cada abordagem.

Do ponto de vista técnico, comparar um modelo multimodal aberto e um modelo multimodal proprietário, ambos acessados por APIs, permite observar diferenças relevantes para Sistemas de Informação sem introduzir a variável de hospedagem local do modelo. A análise passa a se concentrar no comportamento dos modelos diante da mesma tarefa, do mesmo conjunto de imagens, do mesmo prompt-base e do mesmo contrato de saída. Dessa forma, o trabalho busca avaliar se o grau de abertura do modelo, sua documentação, seu custo, sua latência e sua robustez produzem diferenças relevantes na extração estruturada de documentos manuscritos ([SOLAIMAN, 2023](#); [BOMMASANI et al., 2023](#); [National Telecommunications and Information Administration, 2024](#)).

O uso de um fluxo padronizado é necessário para que a comparação seja justa. Ao encapsular a chamada aos modelos em uma camada de integração, o trabalho busca reduzir diferenças externas ao experimento, mantendo equivalentes a imagem enviada, o prompt-base, o contrato JSON esperado e as métricas coletadas.

Além disso, a padronização da saída em JSON e o uso de um validador de esquema contribuem para transformar uma resposta probabilística em um dado operacional que pode ser armazenado, auditado e revisado. Essa transição entre inferência de IA e dado

persistente é uma questão central para a integração de IA em sistemas de informação ([National Institute of Standards and Technology, 2023](#); [RAJI et al., 2020](#); [AMERSHI et al., 2019](#); [MITCHELL et al., 2019](#)).

1.5 Objetivos

1.5.1 Objetivo geral

O objetivo geral deste trabalho é avaliar comparativamente o desempenho de modelos multimodais abertos e proprietários, acessados por APIs, na extração estruturada de informações em provas objetivas manuscritas.

1.5.2 Objetivos específicos

Para alcançar o objetivo geral, os seguintes objetivos específicos foram delineados:

- Definir um conjunto de provas objetivas manuscritas para avaliação experimental.
- Construir um padrão-ouro com os elementos estruturais esperados de cada prova.
- Implementar um fluxo padronizado para captura, envio e processamento das imagens.
- Padronizar a saída dos modelos em JSON.
- Integrar um modelo multimodal aberto.
- Integrar um modelo multimodal proprietário.
- Submeter as mesmas imagens aos modelos avaliados, utilizando o mesmo prompt-base, contrato de saída e métricas.
- Medir acurácia, validade do JSON, latência, custo operacional, robustez e necessidade de validação humana.
- Analisar os principais tipos de erro observados em cada modelo.

2 Referencial Teórico

Este capítulo apresenta os conceitos que fundamentam o trabalho sob a perspectiva de Sistemas de Informação. O foco recai sobre processamento inteligente de documentos, modelos multimodais, padronização de entrada e saída, validação de saídas estruturadas e avaliação experimental de artefatos computacionais.

2.1 Processamento de Documentos Manuscritos

O processamento de documentos manuscritos envolve a conversão de um artefato físico, sujeito a variações de escrita, captura, organização visual e marcação, em registros digitais que possam ser armazenados e utilizados por um sistema. Em provas objetivas manuscritas, a extração de informação exige reconhecer identificação do aluno, enunciados, numeração das questões, alternativas disponíveis, marcações de resposta, rasuras e ambiguidades visuais. A dificuldade aumenta quando a captura ocorre por fotografia, pois o sistema passa a lidar com inclinação, sombras, reflexos, baixa resolução, cortes parciais, caligrafias distintas e leiaute manuscrito irregular. O reconhecimento de manuscritos, tanto em cenários on-line quanto off-line, é um problema consolidado na área de análise de padrões e documentos ([PLAMONDON; SRIHARI, 2000](#); [RASSUL et al., 2025](#)).

Soluções tradicionais baseadas em Reconhecimento Óptico de Marcas (OMR) tendem a funcionar melhor quando há um formulário padronizado e condições controladas de digitalização. Técnicas de OCR, como o Tesseract, e abordagens recentes de OMR, incluindo modelos leves e processamento com câmeras de smartphone, mostram diferentes caminhos para digitalização de documentos e marcações ([SMITH, 2007](#); [MONDAL et al., 2024](#); [HAFEEZ et al., 2024](#)). Já abordagens baseadas em entendimento de documentos podem interpretar simultaneamente texto, leiaute e imagem, reduzindo a dependência de templates rígidos ([XU et al., 2020](#); [KIM et al., 2022](#)). Essa flexibilidade, entretanto, precisa ser avaliada empiricamente antes de ser incorporada a um sistema de informação, especialmente quando o documento é manuscrito.

2.2 Modelos Multimodais

Modelos multimodais de linguagem combinam processamento textual com interpretação visual, permitindo que uma imagem seja fornecida junto de uma instrução textual. No contexto deste trabalho, o modelo recebe a imagem da prova objetiva manuscrita e uma especificação do formato de saída esperado, retornando dados estruturados sobre questões identificadas, alternativas detectadas, respostas marcadas, identificação do aluno,

rasuras, ambiguidades visuais e grau de confiança. Tarefas como VQA em documentos, pré-treinamento com texto e leiaute, e entendimento de documentos sem OCR indicam a relevância dos modelos multimodais para esse tipo de dado visual (MATHEW; KARATZAS; JAWAHAR, 2021; XU et al., 2020; KIM et al., 2022).

Apesar do potencial técnico, a resposta de um modelo multimodal não deve ser tratada automaticamente como dado válido. Como esses modelos são probabilísticos, o sistema precisa considerar respostas incompletas, inconsistentes ou incompatíveis com o esquema esperado. Por isso, o fluxo proposto incorpora validação de JSON, registro de incertezas e revisão humana para casos que não atendem aos critérios de qualidade.

2.3 Modelos Abertos e Modelos Proprietários

A comparação entre modelos abertos e proprietários é relevante para decisões técnicas em Sistemas de Informação. Modelos abertos, frequentemente disponibilizados com pesos abertos e documentação pública, podem oferecer maior transparência sobre características gerais, possibilidade de execução local em cenários futuros e menor barreira para experimentação. Modelos proprietários, por outro lado, costumam ser disponibilizados como serviços fechados, com infraestrutura gerenciada pelo fornecedor, podendo oferecer estabilidade operacional, desempenho superior ou recursos adicionais.

Neste trabalho, ambos os modelos serão acessados por APIs, de modo que a comparação não tem como foco hospedagem local, mas sim o comportamento dos modelos na tarefa de extração estruturada de informações em provas objetivas manuscritas. Como exemplo de enquadramento experimental, um modelo da família Gemma pode representar a categoria de modelo aberto ou *open-weight*, enquanto um modelo da família Gemini pode representar a categoria proprietária, ambos consumidos por APIs documentadas pelo provedor (Google AI for Developers, 2026b; Google AI for Developers, 2026c; Google AI for Developers, 2026a). Essa distinção permite discutir graus de abertura, documentação, custo, latência, validade da saída estruturada e robustez em uma mesma tarefa (SOLAIMAN, 2023; BOMMASANI et al., 2023; National Telecommunications and Information Administration, 2024; National Institute of Standards and Technology, 2023).

2.4 Padronização de Entrada e Saída para Comparação de Modelos

Para comparar modelos diferentes de forma controlada, é necessário padronizar as entradas, o prompt-base, o contrato de saída e as métricas coletadas. Neste trabalho, a camada de integração com os modelos não é tratada como contribuição principal, mas como mecanismo técnico para reduzir variações externas ao experimento. Assim, as imagens das provas, as instruções enviadas aos modelos e o esquema JSON esperado serão mantidos

equivalentes para o modelo aberto e para o modelo proprietário.

A camada *ModelAdapter* funciona como fronteira técnica entre o backend e as APIs dos modelos. Ela recebe uma requisição padronizada, chama o modelo configurado, interpreta a resposta bruta e retorna uma estrutura compatível com o esquema esperado pelo sistema. Essa separação apoia o protocolo experimental, pois permite registrar métricas de execução e manter a mesma rotina de validação humana para ambos os modelos.

2.5 Saída Estruturada e Validação Humana

Em um sistema transacional, uma resposta textual livre produzida por IA não é suficiente. O resultado precisa ser convertido em uma estrutura previsível, validada contra regras formais e persistida com rastreabilidade. Por isso, o trabalho adota uma saída em JSON contendo, no mínimo, identificador da submissão, respostas extraídas, campos de confiança, erros de validação e indicação de revisão humana.

A validação humana é tratada como parte do fluxo, e não como uma etapa externa. Quando o modelo retorna baixa confiança, resposta ausente, alternativa ambígua ou JSON inválido, o sistema apresenta o caso em uma tela de validação. A correção feita pelo usuário é armazenada junto do resultado original, permitindo comparar a saída do modelo com o resultado final validado. Essa abordagem se alinha a recomendações de interação humano-IA, auditoria algorítmica e gestão de riscos em sistemas baseados em IA ([AMERSHI et al., 2019](#); [RAJI et al., 2020](#); [National Institute of Standards and Technology, 2023](#)).

2.6 Design Science Research e Avaliação de Artefatos

A metodologia Design Science Research (DSR) é adequada para este trabalho por orientar a construção e avaliação de artefatos voltados à solução de problemas em Sistemas de Informação ([SPOSITO et al., 2024](#)). O artefato proposto não é apenas uma interface de usuário, mas um fluxo operacional composto por aplicativo, backend, camada de integração com modelos, banco de dados e mecanismos de validação.

A avaliação do artefato será conduzida de forma experimental e comparativa, observando métricas técnicas e operacionais. O Framework for Evaluation in Design Science (FEDS) apoia a definição de avaliações formativas e somativas ao longo do ciclo de desenvolvimento ([VENABLE; PRIES-HEJE; BASKERVILLE, 2016](#)). Neste trabalho, a avaliação final deverá indicar qual abordagem técnica se mostrou mais adequada para o problema definido, considerando não apenas acurácia, mas também custo, latência, taxa de saída válida e necessidade de intervenção humana.

2.7 Trabalhos Relacionados

Diversos trabalhos abordam a correção automática de avaliações objetivas por meio de Reconhecimento Óptico de Marcas (OMR), processamento de imagem e captura por câmera. O Eyegrade, proposto por Fisteus, Pardo e García, utilizou técnicas de visão computacional de baixo custo para corrigir exames de múltipla escolha com webcam (FISTEUS; PARDO; GARCÍA, 2013). Zampirolli, Quilici-Gonzalez e Neves também investigaram a correção automática de testes de múltipla escolha com câmeras digitais (ZAMPIROLI; QUILICI-GONZALEZ; NEVES, 2013), incluindo trabalhos posteriores em dispositivos Android (ZAMPIROLI et al., 2015). Abordagens recentes, como OMRNet e métodos tolerantes a falhas com câmeras de smartphone, reforçam a relevância desse campo (MONDAL et al., 2024; HAFEEZ et al., 2024). Em geral, porém, essas soluções assumem formulários ou folhas de resposta mais estruturadas.

No contexto brasileiro, o sistema Minha Prova propôs a automatização do processo avaliativo escolar (SILVA, 2019), enquanto o trabalho Avalia investigou a correção automatizada de atividades escolares utilizando OCR e inteligência artificial (OLIVEIRA; SILVA, 2024). Mais recentemente, Almeida et al. apresentaram um sistema para geração e correção automática de provas utilizando IA generativa, arquitetura de microsserviços, modelos locais via Ollama, banco vetorial e RAG (ALMEIDA et al., 2025). Esses trabalhos indicam o crescimento do uso de IA em processos avaliativos, mas diferem do presente estudo por concentrarem-se na aplicação educacional, na geração de questões ou na correção automatizada em sentido amplo.

Pesquisas em *document understanding* e modelos multimodais, como LayoutLM, DocVQA, Donut e DocLLM, demonstram a evolução de técnicas capazes de combinar texto, imagem e leiaute (XU et al., 2020; MATHEW; KARATZAS; JAWAHAR, 2021; KIM et al., 2022; WANG et al., 2024). Estudos sobre reconhecimento de manuscritos com LLMs multimodais também indicam o uso recente desses modelos em documentos visualmente complexos (LI, 2024). Esses trabalhos fornecem base técnica para a extração estruturada de documentos, mas não tratam especificamente da comparação experimental entre modelos multimodais abertos e proprietários, ambos acessados por APIs hospedadas, em uma tarefa de extração estruturada de provas objetivas manuscritas.

Dessa forma, a diferença central deste TCC está na avaliação comparativa de modelos multimodais sob um fluxo experimental padronizado, utilizando o mesmo conjunto de imagens, o mesmo prompt-base, o mesmo contrato JSON e as mesmas métricas. A contribuição não se limita ao desenvolvimento de uma aplicação de correção, mas à análise técnica da validade da saída estruturada, da necessidade de validação humana e dos trade-offs de acurácia, custo, latência e robustez.

2.8 Síntese do Referencial

O referencial teórico sustenta que a contribuição deste trabalho está na avaliação comparativa de modelos multimodais em um sistema de informação, com ênfase em extração estruturada de documento manuscrito, padronização de entrada e saída, contrato JSON, validação humana e mensuração experimental. A aplicação em provas objetivas manuscritas oferece um caso concreto para medir o comportamento dos modelos em documentos físicos e visualmente heterogêneos.

3 Metodologia

A condução deste trabalho segue a metodologia Design Science Research (DSR), pois envolve a construção e avaliação de um artefato técnico para um problema de Sistemas de Informação ([SPOSITO et al., 2024](#)). O artefato será um sistema de extração estruturada de informações em provas objetivas manuscritas, avaliado por meio de um experimento comparativo entre dois modelos multimodais acessados por APIs: um modelo aberto e um modelo proprietário.

3.1 Procedimentos Metodológicos

Os procedimentos metodológicos serão organizados em cinco etapas:

1. revisão bibliográfica sobre processamento de documentos manuscritos, modelos multimodais, OMR, fluxos padronizados de comparação, validação humana e avaliação de artefatos;
2. projeto e implementação do artefato, incluindo aplicativo móvel, backend, camada de integração com modelos, validador de JSON e persistência dos resultados;
3. preparação do conjunto de testes, composto por imagens de provas objetivas manuscritas capturadas por smartphone;
4. construção do padrão-ouro por validação manual das respostas e dos elementos estruturais das provas;
5. execução do experimento comparativo, coleta das métricas e análise dos resultados.

3.2 Recursos Necessários

O experimento exigirá recursos de hardware e software. Como hardware, será utilizado um smartphone para captura das imagens e um computador de desenvolvimento. Como software, serão necessários aplicativo móvel, backend, banco de dados, validador de JSON e acesso às APIs dos modelos multimodais avaliados.

O aplicativo móvel terá função limitada à captura das imagens e visualização dos resultados. O processamento ocorrerá no backend e nas APIs dos modelos, não no dispositivo móvel. Como ambos os modelos serão acessados como serviços externos, a análise de privacidade considerará as implicações do envio de imagens e metadados para APIs hospedadas.

3.3 Desenho do Experimento

O experimento será realizado em ambiente controlado de desenvolvimento e teste, com imagens de provas objetivas manuscritas capturadas por smartphone. As mesmas imagens serão enviadas aos dois modelos, utilizando o mesmo prompt-base, o mesmo contrato JSON e as mesmas métricas. A comparação será feita em relação a um padrão-ouro preenchido manualmente.

Serão consideradas provas com variações de caligrafia, iluminação, enquadramento, inclinação, rasuras, marcações ambíguas e leiaute manuscrito irregular. A quantidade final de imagens será definida na fase de preparação do experimento, buscando volume suficiente para permitir comparação entre os provedores sem transformar o projeto em uma avaliação estatística ampla.

O trabalho será executado em quatro etapas principais:

- **Etapa 1:** definição do esquema JSON, preparação das provas e implementação inicial do fluxo de captura e backend.
- **Etapa 2:** integração das APIs do modelo aberto e do modelo proprietário e criação do padrão-ouro manual.
- **Etapa 3:** execução dos testes com ambos os provedores e coleta das métricas.
- **Etapa 4:** análise comparativa, discussão dos erros e redação dos resultados.

3.4 Métricas de Avaliação

As principais métricas do experimento serão:

- acurácia na identificação das questões, alternativas e respostas marcadas;
- acurácia no reconhecimento da identificação manuscrita do aluno, quando houver;
- taxa de respostas em JSON válido;
- latência média por prova processada;
- custo operacional estimado por prova;
- taxa de casos enviados para validação humana;
- tipos de erro observados, como rasura, marcação ambígua, caligrafia ilegível, questão não identificada, JSON inválido ou falha de provedor.

O modelo mais adequado não será definido apenas pela maior acurácia. A análise considerará o equilíbrio entre qualidade da extração, validade da saída estruturada, custo, latência, robustez, implicações de privacidade em APIs hospedadas e necessidade de intervenção humana.

4 Fluxo Experimental e Comparação dos Modelos

A solução proposta consiste em um fluxo experimental padronizado para comparar modelos multimodais abertos e proprietários na extração estruturada de informações em provas objetivas manuscritas. O aplicativo móvel captura a imagem da prova e apresenta o resultado; o backend registra a submissão, envia a imagem aos modelos por meio da camada de integração, valida a resposta em JSON e persiste o resultado. Quando houver baixa confiança, ambiguidade ou erro estrutural, o caso será encaminhado para validação humana.

4.1 Componentes do Fluxo

O fluxo experimental será composto pelos seguintes elementos principais:

- **App móvel:** captura imagens de provas objetivas manuscritas e exibe os resultados.
- **Backend:** orquestra o fluxo de processamento, armazena dados e expõe APIs para o aplicativo.
- **Camada de integração com modelos:** define uma interface comum para comunicação com as APIs avaliadas.
- **OpenModelProvider:** integra o modelo multimodal aberto.
- **ClosedModelProvider:** integra o modelo multimodal proprietário.
- **Validador JSON:** verifica se a resposta segue o contrato de saída esperado.
- **Banco de dados:** armazena resultados, métricas e decisões de validação humana.
- **Validação humana:** revisa casos ambíguos, respostas inválidas ou itens de baixa confiança.

4.2 Contrato de Saída

O contrato de saída será padronizado em JSON para permitir comparação entre modelos. O exemplo do Código 1 ilustra a estrutura esperada, que poderá ser refinada durante a implementação.

```

1 {
2   "submission_id": "sub-001",
3   "student_identifier": "nome reconhecido ou null",
4   "questions": [
5     {
6       "question": 1,
7       "detected_alternatives": ["A", "B", "C", "D"],
8       "selected_option": "A",
9       "confidence": 0.91,
10      "visual_ambiguities": [],
11      "requires_human_review": false
12    }
13  ],
14  "overall_confidence": 0.88,
15  "validation_errors": []
16 }

```

Código 1 – Exemplo de saída padronizada em JSON

4.3 Tabela Comparativa Planejada

Os resultados serão organizados conforme a Tabela 1. Os valores serão preenchidos após a execução do experimento.

Tabela 1 – Comparação experimental entre provedores multimodais

Métrica	Modelo aberto via API	Modelo proprietário via API
Acurácia de extração	A preencher	A preencher
Identificação manuscrita	A preencher	A preencher
Taxa de JSON válido	A preencher	A preencher
Latência média	A preencher	A preencher
Custo por prova	A preencher	A preencher
Validação humana	A preencher	A preencher
Tipos de erro	A preencher	A preencher
Observações técnicas	A preencher	A preencher

5 Expectativa de Conclusão

Ao final do trabalho, espera-se concluir qual abordagem técnica se mostrou mais adequada para a extração estruturada de informações em provas objetivas manuscritas no cenário avaliado. A conclusão poderá favorecer o modelo aberto, o modelo proprietário ou uma estratégia híbrida, conforme os resultados de acurácia, validade do JSON, latência, custo, robustez, implicações de privacidade em APIs e necessidade de validação humana.

Não se pretende concluir que modelos multimodais substituem métodos tradicionais em todos os contextos. A conclusão será limitada ao conjunto de provas, modelos, APIs, prompts, métricas e condições de captura utilizados no experimento. A contribuição esperada é uma análise comparativa técnica, com uma tabela de resultados e discussão dos principais trade-offs para Sistemas de Informação.

6 Conclusão

Este projeto de TCC propõe o desenvolvimento e a avaliação de um fluxo padronizado para extração estruturada de informações em provas objetivas manuscritas. O foco está na comparação entre dois modelos multimodais acessados por APIs: um modelo aberto e um modelo proprietário. O aplicativo móvel será utilizado apenas para captura das imagens e visualização dos resultados, enquanto o processamento será realizado pelo backend e pelas APIs dos modelos avaliados.

A expectativa de conclusão é identificar, com base no experimento planejado, qual abordagem apresenta melhor equilíbrio entre acurácia, validade da saída JSON, latência, custo operacional, robustez e necessidade de validação humana. Assim, o resultado esperado não é apenas demonstrar um aplicativo funcionando, mas produzir uma análise comparativa útil para decisões técnicas em Sistemas de Informação.

O estudo permanecerá limitado ao conjunto de provas, modelos, APIs, prompts e métricas definidos no projeto. Mesmo assim, espera-se que a avaliação permita discutir de forma objetiva os trade-offs entre um modelo multimodal aberto e um modelo multimodal proprietário ambos acessados via API.

Referências

- ALMEIDA, D. et al. Estudo e desenvolvimento de um sistema para geração e correção automática de provas utilizando inteligência artificial. In: *Anais do Seminário de Iniciação Científica e Tecnológica do IFG*. [S.l.: s.n.], 2025. v. 18, n. 1.
- AMERSHI, S. et al. Guidelines for human-ai interaction. In: *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. [S.l.: s.n.], 2019. p. 1–13.
- BOMMASANI, R. et al. The foundation model transparency index. *arXiv preprint arXiv:2310.12941*, 2023. Disponível em: <<https://arxiv.org/abs/2310.12941>>.
- FISTEUS, J. A.; PARDO, A.; GARCÍA, N. F. Grading multiple choice exams with low-cost and portable computer-vision techniques. *Journal of Science Education and Technology*, v. 22, n. 4, p. 560–571, 2013.
- Google AI for Developers. *Gemini API documentation*. 2026. Acesso em: 10 jun. 2026. Disponível em: <<https://ai.google.dev/gemini-api/docs>>.
- Google AI for Developers. *Gemma models overview*. 2026. Acesso em: 10 jun. 2026. Disponível em: <<https://ai.google.dev/gemma/docs>>.
- Google AI for Developers. *Use Gemma with the Gemini API*. 2026. Acesso em: 10 jun. 2026. Disponível em: <https://ai.google.dev/gemma/docs/core/gemma_on_gemini_api>.
- HAFEEZ, Q. et al. An enhanced fault tolerance algorithm for optical mark recognition using smartphone cameras. *IEEE Access*, v. 12, p. 121305–121319, 2024.
- KIM, G. et al. Ocr-free document understanding transformer. In: *European Conference on Computer Vision*. [S.l.: s.n.], 2022. p. 498–517.
- LI, L. Handwriting recognition in historical documents with multimodal llm. *arXiv preprint arXiv:2410.24034*, 2024. Disponível em: <<https://arxiv.org/abs/2410.24034>>.
- MATHEW, M.; KARATZAS, D.; JAWAHAR, C. V. Docvqa: A dataset for vqa on document images. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. [s.n.], 2021. p. 2200–2209. Disponível em: <<https://arxiv.org/abs/2007.00398>>.
- MITCHELL, M. et al. Model cards for model reporting. In: *Proceedings of the Conference on Fairness, Accountability, and Transparency*. [S.l.: s.n.], 2019. p. 220–229.
- MONDAL, S. et al. Omrnet: A lightweight deep learning model for optical mark recognition. *Multimedia Tools and Applications*, v. 83, p. 14011–14045, 2024.
- National Institute of Standards and Technology. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. [S.l.], 2023. Disponível em: <<https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf>>.
- National Telecommunications and Information Administration. *Dual-Use Foundation Models with Widely Available Model Weights: Report to the President*. [S.l.], 2024. Disponível em: <<https://www.ntia.gov/sites/default/files/publications/ntia-ai-open-model-report.pdf>>.

- OLIVEIRA, A. P. d.; SILVA, G. S. V. d. *Avalia: sistema de correção automatizada de atividades escolares utilizando reconhecimento óptico de caracteres e inteligência artificial*. Monografia (Trabalho de Conclusão de Curso) — Universidade Estadual Paulista, Bauru, 2024. Disponível em: <<https://repositorio.unesp.br/server/api/core/bitstreams/45e3e419-5bd7-4b02-9f93-580883012154/content>>.
- PLAMONDON, R.; SRIHARI, S. N. On-line and off-line handwriting recognition: a comprehensive survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 22, n. 1, p. 63–84, 2000.
- RAJI, I. D. et al. Closing the ai accountability gap: Defining an end-to-end framework for internal algorithmic auditing. In: *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. [S.l.: s.n.], 2020. p. 33–44.
- RASSUL, Y. H. et al. Advancing offline handwritten text recognition: A systematic review of data augmentation and generation techniques. *arXiv preprint arXiv:2507.06275*, 2025. Disponível em: <<https://arxiv.org/abs/2507.06275>>.
- SILVA, T. d. S. *Minha Prova: Automatizando o processo avaliativo nas escolas*. Monografia (Trabalho de Conclusão de Curso) — Universidade Federal Rural de Pernambuco, Recife, 2019.
- SMITH, R. An overview of the tesseract ocr engine. In: *Proceedings of the Ninth International Conference on Document Analysis and Recognition*. [S.l.: s.n.], 2007. v. 2, p. 629–633.
- SOLAIMAN, I. The gradient of generative ai release: Methods and considerations. In: *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency*. [s.n.], 2023. Disponível em: <<https://arxiv.org/abs/2302.04844>>.
- SPOSITO, L. et al. Design science research: um estudo sobre o ensino do método. *Revista Ciências Administrativas*, v. 30, p. 1–18, 2024.
- VENABLE, J.; PRIES-HEJE, J.; BASKERVILLE, R. Feds: a framework for evaluation in design science research. *European journal of information systems*, Taylor & Francis, v. 25, n. 1, p. 77–89, 2016.
- WANG, D. et al. Docllm: A layout-aware generative language model for multimodal document understanding. *arXiv preprint arXiv:2401.00908*, 2024. Disponível em: <<https://arxiv.org/abs/2401.00908>>.
- XU, Y. et al. Layoutlm: Pre-training of text and layout for document image understanding. In: *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2020. p. 1192–1200.
- ZAMPIROLI, F. d. A. et al. Automatic correction of multiple-choice tests on android devices. In: *Workshop de Visão Computacional*. São Carlos, Brasil: [s.n.], 2015.
- ZAMPIROLI, F. d. A.; QUILICI-GONZALEZ, J. A.; NEVES, R. P. d. O. Automatic correction of multiple-choice tests using digital cameras and image processing. In: *Workshop de Visão Computacional*. Rio de Janeiro, Brasil: [s.n.], 2013.