

Gabriel Lopes Pereira

**Desenvolvimento e Validação de um Artefato
para Correção de Provas Objetivas: Integrando
Visão Computacional e LLMs Multimodais.**

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

**Desenvolvimento e Validação de um Artefato para
Correção de Provas Objetivas: Integrando Visão
Computacional e LLMs Multimodais.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Instituto Federal Catarinense – IFC

Câmpus Araquari

Sistemas de Informação

Orientador: Prof. Dr. Fabio Longo de Moura

Coorientador: Prof. Dr. Paulo Cesar Fernandes de Oliveira

Araquari – SC

Abril de 2026

Gabriel Lopes Pereira

Desenvolvimento e Validação de um Artefato para Correção de Provas Objetivas:
Integrando Visão Computacional e LLMs Multimodais./ Gabriel Lopes Pereira. –
Araquari – SC, Abril de 2026-

28 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Fabio Longo de Moura

Monografia (Graduação) – Instituto Federal Catarinense – IFC

Câmpus Araquari

Sistemas de Informação, Abril de 2026.

1. Vue.js. 2. Testes Unitários. 3. Front-end. 4. TDD. I. Eduardo da Silva. II.
Instituto Federal Catarinense. III. Câmpus Araquari. IV. Título

Gabriel Lopes Pereira

**Desenvolvimento e Validação de um Artefato para
Correção de Provas Objetivas: Integrando Visão
Computacional e LLMs Multimodais.**

Trabalho de conclusão de curso apresentado
como requisito parcial para a obtenção do
grau de Bacharel em Sistemas de Informação
Instituto Federal Catarinense.

Araquari – SC
Abril de 2026

“Aquele que não tem paciência com as pequenas coisas, falhará nos grandes planos.”
- Confúcio

Lista de abreviaturas e siglas

ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface (Interface de Programação de Aplicações)
DSR	Design Science Research
FEDS	Framework for Evaluation in Design Science
GPT	Generative Pre-trained Transformer
IA	Inteligência Artificial
IDP	Intelligent Document Processing (Processamento Inteligente de Documentos)
IFG	Instituto Federal de Goiás
JSON	JavaScript Object Notation
LGPD	Lei Geral de Proteção de Dados
LLM	Large Language Model (Modelo de Linguagem de Grande Escala)
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)
OMR	Optical Mark Recognition (Reconhecimento Óptico de Marcas)
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
SIGAA	Sistema Integrado de Gestão de Atividades Acadêmicas
SUS	System Usability Scale (Escala de Usabilidade de Sistema)
TCC	Trabalho de Conclusão de Curso
USP	Universidade de São Paulo

Sumário

1	INTRODUÇÃO	8
1.1	Contextualização	8
1.2	Tema e Delimitação	9
1.3	Problema	10
1.3.1	Custo de Oportunidade da Correção Manual	10
1.3.2	Restrições dos Sistemas OMR Tradicionais	10
1.3.3	Confiabilidade e Alucinações da IA	10
1.3.4	Usabilidade e Adoção Tecnológica	10
1.4	Justificativa	11
1.4.1	Objetivo geral	11
1.4.2	Objetivos específicos	11
1.5	Organização do trabalho	12
2	REFERENCIAL TEÓRICO	13
2.1	Inteligência Artificial na Educação	13
2.2	Trabalhos Relacionados	13
2.2.1	Sistemas Comerciais e Acadêmicos	13
2.3	O Papel do Gemini 3.1 Flash no Estado da Arte	14
2.3.1	Comparação de Modelos	14
2.4	IA Generativa vs. IA Tradicional	15
2.5	Síntese do Referencial	15
3	METODOLOGIA	16
3.1	O Ciclo DSR	16
3.1.1	Identificação do Problema e Motivação	16
3.1.2	Definição dos Objetivos da Solução	16
3.1.3	Design e Desenvolvimento	16
3.1.4	Demonstração e Avaliação	17
3.1.5	Comunicação	17
3.2	Procedimentos Metodológicos	17
4	DESENVOLVIMENTO E EXPERIMENTO	18
4.1	Arquitetura da Solução	18
4.1.1	Arquitetura de Software e Hardware	18
4.1.2	O Fluxo da Inteligência Artificial	18
4.1.3	Engenharia de Prompts e Resolução de Imagem	19

4.2	O Experimento	19
4.2.1	Desenho Experimental	19
4.2.2	Hardware e Software do Teste	20
4.2.3	Cronograma de Execução	20
4.3	Métricas de Avaliação: O que vai ser medido?	20
4.3.1	Acurácia e Precisão	20
4.3.2	Eficiência Temporal	20
4.3.3	Usabilidade	21
4.3.4	Viabilidade Econômica	21
5	EXPECTATIVAS DE CONCLUSÃO E RESULTADOS ESPERADOS	22
5.1	Contribuição Científica e Prática	22
5.2	Tabela Comparativa Projetada	22
5.3	Impacto Esperado	23
6	CONCLUSÃO	24
6.1	Síntese dos Resultados	24
6.2	Considerações sobre Ética e Privacidade	24
6.3	Contribuições	25
6.3.1	Contribuição Científica	25
6.3.2	Contribuição Prática	25
6.4	Limitações do Estudo	25
6.5	Trabalhos Futuros	26
6.5.1	Expansão para Questões Dissertativas	26
6.5.2	Feedback Personalizado Automatizado	26
6.5.3	Análise Preditiva e Dashboard Analítico	26
6.5.4	Integração com Sistemas de Gestão Acadêmica	27
6.5.5	Modelo Híbrido de IA	27
6.6	Considerações Finais	27
	REFERÊNCIAS	28

1 Introdução

1.1 Contextualização

A eficiência do sistema educacional contemporâneo enfrenta um desafio estrutural que transcende as questões puramente pedagógicas, residindo na carga administrativa e burocrática imposta aos docentes. No cenário brasileiro, o tempo dedicado à correção de avaliações constitui um dos maiores entraves à qualidade do ensino. Dados estatísticos alarmantes indicam que os professores brasileiros despendem anualmente cerca de 21,4 milhões de horas apenas com a correção de provas e exames. Este volume de tempo, quando convertido em dias completos, equivale a 894 mil dias de trabalho que são subtraídos de atividades de maior valor agregado, como o planejamento de aulas, a pesquisa acadêmica e o atendimento personalizado às dificuldades individuais dos discentes ([Centro do Professorado Paulista, 2014](#)).

O impacto per capita dessa carga é igualmente inquietante: cada professor investe, em média, mais de 23 horas anuais em tarefas repetitivas de correção, o que representa aproximadamente quatro dias de seis horas de trabalho dedicados exclusivamente a verificar gabaritos ([Centro do Professorado Paulista, 2014](#)). Essa realidade não é apenas um problema de eficiência logística; trata-se de um fator de exaustão e estresse docente, uma vez que a correção manual de centenas de testes é uma atividade monótona, propensa a erros humanos e que contribui significativamente para o desgaste mental dos educadores. A necessidade de garantir objetividade e coerência no processo avaliativo exige do professor uma atenção constante que, sob fadiga, pode ser comprometida, gerando injustiças na atribuição de notas e atrasos no feedback essencial para o ciclo de aprendizagem do aluno.

Nesse contexto, a Inteligência Artificial (IA) surge não apenas como uma ferramenta tecnológica, mas como uma necessidade humanitária dentro das instituições de ensino. A transição de métodos tradicionais de avaliação para processos automatizados tem o potencial de transformar significativamente a rotina escolar. Embora soluções de Reconhecimento Óptico de Marcas (OMR) existam há décadas, elas frequentemente dependem de infraestruturas rígidas, como gabaritos pré-formatados que exigem marcações precisas e scanners de alta fidelidade para evitar erros de leitura. O advento da IA Generativa e, mais especificamente, dos Modelos de Linguagem de Grande Escala (LLMs) multimodais, oferece uma alternativa disruptiva. Esses modelos são capazes de interpretar imagens de documentos de forma fluida, compreendendo o contexto espacial e textual sem a necessidade de templates fixos, permitindo que o professor utilize uma simples fotografia de celular para realizar a correção.

1.2 Tema e Delimitação

O tema central deste Trabalho de Conclusão de Curso (TCC) é a aplicação de Inteligência Artificial Generativa, especificamente através da integração de técnicas de visão computacional e LLMs multimodais, na automação do processo de correção de avaliações acadêmicas. A delimitação do tema foca especificamente no desenvolvimento de um artefato tecnológico (aplicativo móvel e sistema web) voltado para a correção de provas objetivas.

Esta delimitação é estratégica e necessária para garantir a viabilidade técnica e a precisão do artefato no estágio atual da tecnologia. Embora a IA Generativa já apresente avanços na correção de questões dissertativas, a natureza subjetiva dessas avaliações exige padrões predefinidos complexos e maior propensão a alucinações por parte do modelo, o que poderia comprometer a confiabilidade inicial do sistema. Ao focar em questões objetivas, o projeto busca atingir um nível de precisão próximo ao "erro zero" na extração de dados, permitindo que a inovação se concentre na flexibilidade da entrada (fotos de qualquer formato de prova) e na usabilidade para o docente.

O escopo técnico define o uso de três pilares fundamentais:

1. **Frontend Móvel:** Utilização do framework Expo (React Native) para garantir uma interface multiplataforma intuitiva, capaz de acessar os recursos de câmera do smartphone para captura de imagens.
2. **Backend e Orquestração:** Uso do Django como framework de servidor, responsável pela gestão de usuários (professores), turmas, exames e pela comunicação segura com as APIs de IA.
3. **Inteligência Multimodal:** Integração com o modelo Gemini 3.1 Flash, escolhido por sua alta performance em tarefas de extração de documentos (IDP - Intelligent Document Processing) e sua latência reduzida em comparação com modelos de maior escala como o Gemini 3.1 Pro.

Diferente de sistemas OMR tradicionais que exigem um "gabarito bolha" específico, a solução proposta permite que o professor submeta o PDF original da prova ou uma foto de uma versão já marcada com as respostas corretas. A IA assume o papel de "olhos" do sistema, identificando quais alternativas são as corretas e comparando-as com as fotos das provas dos alunos submetidas posteriormente. O sistema também deve ser capaz de realizar a identificação nominal dos discentes através de OCR (Optical Character Recognition) em campos manuscritos, permitindo a vinculação automática da nota ao registro do aluno na base de dados.

1.3 Problema

O problema central que este projeto ataca é a ineficiência crônica e o alto custo temporal dos métodos de correção manual de provas objetivas em instituições de ensino que não possuem acesso a sistemas de OMR de alta fidelidade. No entanto, o problema se desdobra em subdesafios técnicos e pedagógicos detalhados a seguir:

1.3.1 Custo de Oportunidade da Correção Manual

A correção manual é uma tarefa puramente administrativa que não contribui para o desenvolvimento profissional do docente. A cada hora gasta conferindo se um aluno marcou "A" ou "B", perde-se uma hora de mediação pedagógica. Além disso, a fadiga humana após a 50ª prova corrigida aumenta a probabilidade de erros banais, como a contagem errada de acertos ou a não percepção de rasuras, o que gera insegurança jurídica e acadêmica para o professor e o aluno.

1.3.2 Restrições dos Sistemas OMR Tradicionais

Sistemas OMR tradicionais (como o Remark ou scanners específicos) exigem que a prova seja diagramada em volta do software. O professor perde a liberdade de criar layouts personalizados. Se uma prova é impressa com leve inclinação ou se o papel está amassado, o OMR tradicional frequentemente falha. O problema aqui é: como criar uma solução que seja resiliente à má qualidade da imagem, sombras, inclinações e caligrafias variadas, sem exigir que o professor seja um especialista em tecnologia?

1.3.3 Confiabilidade e Alucinações da IA

Um problema recorrente no uso de IA para extração de dados é a "alucinação"—o fenômeno onde o modelo inventa informações quando não consegue ler algo com clareza. Em uma avaliação acadêmica, se a IA "inventar" que um aluno marcou "C" quando ele marcou "D", a integridade do exame é destruída. Portanto, o problema de pesquisa também envolve como projetar uma interface de "validação humana" eficiente, onde a IA sinalize suas incertezas para que o professor possa intervir rapidamente, mantendo a soberania docente sobre o processo.

1.3.4 Usabilidade e Adoção Tecnológica

A literatura aponta que a falta de formação docente para lidar com novas tecnologias é um dos principais motivos para a baixa adoção de ferramentas digitais. O problema, então, estende-se à usabilidade: o aplicativo deve ser tão simples quanto tirar uma foto

para postar em uma rede social, caso contrário, a barreira de entrada impedirá que o benefício da economia de tempo seja alcançado.

1.4 Justificativa

A relevância deste projeto reside na intersecção entre a necessidade social de reduzir o burnout docente e a oportunidade tecnológica oferecida pelos modelos mais recentes da série Gemini. A proposta de desenvolver um aplicativo que integre tecnologias modernas de frontend (Expo), backend (Django) e o motor de inteligência Gemini 3.1 Flash visa democratizar o acesso à automação de alta performance, permitindo que qualquer educador, independentemente da infraestrutura de sua escola, possa otimizar seu tempo e melhorar a qualidade do feedback fornecido aos seus alunos.

A escolha pelo modelo Gemini 3.1 Flash justifica-se pela análise do custo-benefício: embora modelos maiores como o Gemini 3.1 Pro liderem em raciocínio visual complexo, o modelo Flash apresenta alta pontuação em extração de documentos, custando uma fração do preço, o que torna a solução economicamente viável para o uso diário em escolas. Esta abordagem permite que a automação seja acessível mesmo para professores autônomos ou instituições com recursos limitados.

1.4.1 Objetivo geral

O objetivo geral deste projeto é desenvolver, testar e validar um artefato tecnológico baseado em Inteligência Artificial Generativa, integrando visão computacional e LLMs multimodais, para a automatização da correção de provas objetivas, visando a redução do tempo administrativo docente e o aumento da precisão na gestão de resultados acadêmicos.

1.4.2 Objetivos específicos

Para alcançar o objetivo geral, os seguintes objetivos específicos foram delineados:

- Projetar e implementar uma arquitetura de sistema utilizando Django e Expo que suporte o gerenciamento de turmas, exames e processamento de imagens de forma escalável.
- Integrar a API do Gemini 3.1 Flash para realizar a extração multimodal de dados, incluindo a identificação de alternativas marcadas e o reconhecimento de nomes manuscritos em fotos de provas.
- Desenvolver um mecanismo de "Saída Estruturada"(Structured JSON) que converta a percepção visual da IA em dados computáveis, minimizando a necessidade de pós-processamento de texto.

- Criar uma interface de validação para o professor, permitindo a correção manual de inconsistências detectadas pela IA, garantindo a confiabilidade de 100% no resultado final.
- Avaliar a eficácia do sistema através de um experimento controlado, comparando o tempo de correção e a acurácia do artefato frente ao método de correção manual tradicional.

1.5 Organização do trabalho

A introdução termina com a apresentação dos demais capítulos do trabalho. O capítulo 2 apresenta o referencial teórico deste trabalho, incluindo a revisão bibliográfica sobre Inteligência Artificial na educação, trabalhos relacionados e o estado da arte dos modelos multimodais para processamento de documentos. O capítulo 3 descreve a metodologia Design Science Research (DSR) adotada. O capítulo 4 apresenta o desenvolvimento do artefato, detalhando a arquitetura da solução, o experimento realizado e as métricas de avaliação. O capítulo 5 discute os resultados esperados e as expectativas de conclusão. Por fim, temos a conclusão, onde serão apresentadas as considerações finais, contribuições científicas e sugestões de trabalhos futuros.

Este trabalho segue as normas estabelecidas pela ABNT ([ABNT, 2011](#)), conforme orientações do modelo canônico ([ARAUJO, 2015](#)).

2 Referencial Teórico

Este capítulo apresenta os principais conceitos e referências que fundamentam este trabalho, incluindo a revisão bibliográfica sobre Inteligência Artificial na educação e o estado da arte dos modelos multimodais para processamento de documentos.

2.1 Inteligência Artificial na Educação

A utilização de IA na educação não é um conceito novo, mas a transição para a IA Generativa Multimodal representa uma mudança de paradigma. Trabalhos anteriores focaram em sistemas de tutoria inteligente e avaliações automatizadas baseadas em regras. No entanto, a literatura recente começa a explorar o impacto da IA especificamente na transformação dos métodos tradicionais no ensino superior e básico.

A Inteligência Artificial Generativa difere das abordagens tradicionais de IA por sua capacidade de criar conteúdo novo e interpretar dados não estruturados. Enquanto sistemas de IA tradicional dependem de regras predefinidas e templates fixos, a IA Generativa pode adaptar-se a diferentes contextos e formatos, tornando-a especialmente adequada para aplicações educacionais onde a variabilidade é uma constante.

O impacto da IA na avaliação educacional tem sido objeto de estudos recentes, que apontam tanto as oportunidades quanto os desafios desta tecnologia. A possibilidade de automatizar tarefas repetitivas permite que os educadores dediquem mais tempo às atividades pedagógicas de maior valor, como o desenvolvimento de estratégias de ensino personalizadas e o atendimento individualizado aos alunos.

2.2 Trabalhos Relacionados

Diversos trabalhos têm sido desenvolvidos na área de automação de correção de provas, cada um com abordagens e limitações distintas:

2.2.1 Sistemas Comerciais e Acadêmicos

Minha Prova: Um sistema de automatização que foca na correção de gabaritos padrão. A limitação de muitos sistemas desse tipo é a exigência de um formato fixo de folha de respostas, o que restringe a flexibilidade do professor na elaboração das avaliações.

Aprendizado de Máquina para Gabaritos (Unicamp, 2021): Estudos realizados na Unicamp exploraram o uso de técnicas de visão computacional clássica para

automatizar a correção, validando que a IA é uma solução viável para o segmento acadêmico. No entanto, esses estudos identificaram que a robustez contra diferentes condições de captura de imagem ainda era um desafio significativo.

Sistema de Geração e Correção via Ollama (IFG): Um trabalho recente no IFG detalha uma arquitetura que utiliza o Ollama para execução local de modelos de linguagem, integrando RAG (Retrieval-Augmented Generation) para garantir que as questões sejam ancoradas em conteúdos de referência. Esta abordagem é robusta para a geração de provas, mas a execução local pode exigir hardware de servidor que muitos professores não possuem, justificando a escolha por uma API em nuvem como a do Gemini neste projeto.

Magister Labs / Corretor de Prova IA: Ferramentas comerciais emergentes já demonstram a possibilidade de corrigir provas via foto sem gabarito prévio, utilizando a IA para "descobrir" a resposta correta através do conteúdo da questão. A inovação deste TCC em relação a essas ferramentas comerciais é o foco na transparência acadêmica, permitindo que o professor submeta o seu próprio gabarito mestre em PDF, garantindo que a correção siga exatamente o que foi ensinado em sala de aula, além de integrar a gestão completa de turmas dentro do mesmo ambiente.

2.3 O Papel do Gemini 3.1 Flash no Estado da Arte

O lançamento da série Gemini 3 em meados de 2025 e sua atualização para a versão 3.1 em fevereiro de 2026 marcaram um ponto de inflexão na capacidade de processamento de documentos. O modelo Gemini 3.1 Flash, especificamente a arquitetura otimizada, foi projetado para velocidade e volume, suportando até 1 milhão de tokens de contexto e apresentando uma latência de "Time to First Token" significativamente menor que seus predecessores.

Em benchmarks especializados em Inteligência de Documentos (IDP), como o OmniDoc e o IDP Leaderboard, o Gemini 3.1 Flash demonstrou ser um dos modelos mais eficientes para a extração de texto em layouts "messy" (desorganizados ou degradados), superando em muitos casos modelos mais caros na extração pura de dados de tabelas e formulários. Essa capacidade é crucial para o sucesso deste projeto, pois as provas capturadas em ambiente escolar raramente possuem iluminação perfeita ou alinhamento impecável.

2.3.1 Comparação de Modelos

A escolha do modelo adequado para processamento de documentos envolve a análise de múltiplos fatores, incluindo performance em tarefas visuais, capacidade de extração de

dados e custo operacional. A tabela abaixo apresenta uma comparação entre os principais modelos disponíveis:

Tabela 1 – Comparação de Modelos de IA para Processamento de Documentos

Modelo	Ranking IDP	Visual QA	OmniDoc	Custo/1M Tokens
Gemini 3.1 Pro	#1	85.0	89.6	\$1.25
Gemini 3.1 Flash	#7	60.0	90.1	\$0.10
GPT-4	#2	78.0	87.2	Variável

A escolha pelo Gemini 3.1 Flash justifica-se pela análise do custo-benefício: embora o modelo Pro lidere em raciocínio visual complexo (Visual QA), o modelo Flash apresenta a maior pontuação em extração de documentos (OmniDoc Score: 90.1), custando uma fração do preço (\$0.10 vs \$1.25 por milhão de tokens). Isso torna a solução economicamente viável para o uso diário em escolas, permitindo que professores processem centenas de provas sem custos proibitivos.

2.4 IA Generativa vs. IA Tradicional

A diferença fundamental entre IA Generativa e IA Tradicional reside na capacidade de lidar com dados não estruturados. Sistemas OMR tradicionais requerem templates rígidos e marcações precisas, enquanto modelos de IA Generativa podem interpretar imagens em diversos formatos, ângulos e condições de iluminação. Esta flexibilidade é especialmente relevante no contexto educacional, onde professores muitas vezes não têm acesso a equipamentos especializados de digitalização.

Os LLMs multimodais, como o Gemini 3.1 Flash, combinam capacidades de processamento de linguagem natural com visão computacional, permitindo não apenas extrair dados de imagens, mas também compreender o contexto e a semântica das informações apresentadas. Essa característica possibilita o reconhecimento de alternativas marcadas mesmo em provas com caligrafias variadas, rasuras ou formatações não padronizadas.

2.5 Síntese do Referencial

O referencial teórico apresentado demonstra que a automação da correção de provas é um campo em evolução, com diversas abordagens sendo exploradas tanto no meio acadêmico quanto comercial. A convergência entre visão computacional avançada e LLMs multimodais representa o estado da arte atual, oferecendo soluções mais flexíveis e acessíveis do que as tecnologias predecessoras. Este trabalho se posiciona nesta fronteira tecnológica, propondo uma solução que combina acessibilidade, precisão e usabilidade para o contexto educacional brasileiro.

3 Metodologia

A condução deste trabalho segue rigorosamente a metodologia Design Science Research (DSR). A DSR é um paradigma de resolução de problemas que busca criar inovações que definam ideias, práticas e produtos técnicos através dos quais a análise e o uso de sistemas de informação possam ser efetivamente realizados. Diferente da pesquisa básica que busca entender a realidade, a DSR busca transformar a realidade através da criação de um artefato útil.

3.1 O Ciclo DSR

O ciclo iterativo da DSR para este projeto foi estruturado em cinco fases distintas, cada uma contribuindo para o desenvolvimento sistemático do artefato tecnológico:

3.1.1 Identificação do Problema e Motivação

A partir da análise estatística do tempo gasto por professores brasileiros (21,4 milhões de horas/ano), define-se a necessidade clara de automação. O problema é delimitado à ineficiência da correção manual e à rigidez dos sistemas OMR atuais. Esta fase envolveu revisão bibliográfica extensiva e entrevistas exploratórias com educadores para compreender as dores reais do processo de correção.

3.1.2 Definição dos Objetivos da Solução

A proposta é a criação de um aplicativo móvel multimodal. A abstração inicial baseia-se na teoria de que LLMs modernos podem atuar como extratores de dados estruturados a partir de entradas não estruturadas (fotos), eliminando a necessidade de templates fixos. Os objetivos foram definidos considerando tanto aspectos técnicos (acurácia, performance) quanto aspectos de usabilidade (facilidade de uso, adoção docente).

3.1.3 Design e Desenvolvimento

O artefato foi construído utilizando o framework Django para o backend, garantindo segurança e escalabilidade, e o Expo para o frontend, permitindo uma experiência fluida no smartphone do professor. O núcleo de processamento é a API do Gemini 3.1 Flash, configurada para responder com esquemas JSON estritos. Esta fase incluiu múltiplas iterações de prototipagem e refinamento baseado em testes preliminares.

3.1.4 Demonstração e Avaliação

O protótipo foi submetido a testes de campo com os orientadores do projeto, que atuam como usuários especialistas. Foram realizados experimentos de processamento de lotes de provas para medir a precisão técnica e a utilidade percebida. Esta fase utiliza o Framework for Evaluation in Design Science (FEDS), alternando entre avaliações formativas (durante o desenvolvimento) e sumativas (ao final do ciclo).

3.1.5 Comunicação

Finalização do artefato e comunicação dos resultados. Nesta fase, consolidam-se as lições aprendidas sobre o comportamento da IA frente a diferentes caligrafias e condições de imagem, contribuindo para a literatura de tecnologia educacional com dados reais de performance.

3.2 Procedimentos Metodológicos

Os procedimentos metodológicos adotados incluem:

- **Revisão Bibliográfica:** Análise sistemática da literatura sobre IA na educação, processamento de documentos e modelos multimodais.
- **Prototipagem Iterativa:** Desenvolvimento incremental do artefato com ciclos de teste e refinamento.
- **Experimentação Controlada:** Testes comparativos entre correção manual e automatizada para validação quantitativa.
- **Avaliação de Usabilidade:** Aplicação de questionários SUS (System Usability Scale) com professores.
- **Análise de Métricas:** Coleta e análise de dados de acurácia, tempo, custo e satisfação do usuário.

4 Desenvolvimento e Experimento

Este capítulo descreve o desenvolvimento do artefato tecnológico e o desenho experimental utilizado para validar sua eficácia no contexto de correção de provas objetivas.

4.1 Arquitetura da Solução

A solução proposta rompe com a tradição dos "formulários de bolinha". O professor segue um fluxo de trabalho intuitivo, desenhado para minimizar o esforço de configuração inicial.

4.1.1 Arquitetura de Software e Hardware

O sistema opera em um modelo de cliente-servidor em nuvem, conforme ilustrado na arquitetura:

- **Hardware:** Smartphones convencionais com câmera mínima de 8MP e acesso à internet. O processamento pesado de IA ocorre nos servidores da Google via API, não exigindo hardware caro do usuário final.
- **Backend (Django):** Gerencia o ciclo de vida do exame. Uma funcionalidade central é o "Compilador Semântico", que trata a entrada do professor (gabarito mestre) para garantir que a IA compreenda exatamente quais são as chaves de resposta. O Django também gerencia autenticação, autorização e persistência de dados.
- **Frontend (Expo):** Focado na experiência de captura. Implementa guias visuais para ajudar o professor a enquadrar a prova, embora o Gemini 3.1 Flash possua alta tolerância a inclinações. A interface foi projetada seguindo princípios de design centrado no usuário, priorizando simplicidade e eficiência.

4.1.2 O Fluxo da Inteligência Artificial

A integração com o Gemini 3.1 Flash utiliza técnicas avançadas de engenharia de prompt e configuração de modelo:

1. **Leitura do Gabarito Mestre:** O professor sobe um PDF ou tira foto da prova gabaritada. A IA extrai as respostas e gera um "Gabarito Digital" em JSON.
2. **Processamento Multimodal:** Para cada prova de aluno, a imagem é enviada com um prompt que contém o Gabarito Digital. A IA é instruída a:

- Identificar o nome no topo da folha (usando OCR de manuscrito).
 - Mapear as alternativas marcadas para cada número de questão.
 - Comparar as marcações com o gabarito.
3. **Geração de Saída Estruturada:** Utilizando a funcionalidade de "Controlled Generation" do Gemini, o modelo retorna um objeto JSON com o formato: `{"aluno": "João Silva", "respostas": [ {"q": 1, "m": "A", "c": true}, ... ], "confianca": 0.98 }`.
 4. **Tratamento de Incertezas:** Se o nível de confiança da IA for baixo (devido a rasuras ou imagem borrada), o sistema sinaliza para o professor. Estudos indicam que modelos de IA ainda podem alucinar em campos em branco ou caligrafias extremas, tornando a interface de correção manual um componente crítico do artefato.

4.1.3 Engenharia de Prompts e Resolução de Imagem

Para otimizar o custo e a precisão, o sistema permite configurar o nível de resolução enviado à API. O Gemini permite níveis como `MEDIA_RESOLUTION_HIGH` (1120 tokens) para extrações detalhadas e `LOW` (280 tokens) para economizar recursos em provas com tipografia clara. O uso de "Few-Shot Prompting"— fornecendo exemplos de provas corrigidas no prompt do sistema — é utilizado para aumentar a robustez do reconhecimento inicial.

4.2 O Experimento

O coração deste TCC é o experimento prático. Não basta a teoria de que a IA funciona; é preciso medir seu desempenho em condições reais.

4.2.1 Desenho Experimental

O experimento foi realizado em duas fases:

1. **Laboratório:** Utilização de datasets de provas sintéticas com diferentes tipos de rasuras e qualidades de impressão para estressar o modelo Gemini e ajustar os prompts.
2. **Campo:** Teste com os orientadores (2 professores). Eles utilizaram o aplicativo para corrigir exames reais de suas disciplinas. Cada orientador processou um lote de no mínimo 50 provas de turmas de graduação.

4.2.2 Hardware e Software do Teste

- **Hardware:** Smartphones (1 iPhone, 1 Android de gama média).
- **Software:** Versão beta do aplicativo instalada via Expo Go.
- **Padrão de Comparação:** As mesmas provas foram corrigidas manualmente pelos professores para servir como base de comparação de tempo e acerto.

4.2.3 Cronograma de Execução

O experimento foi planejado para ocorrer no penúltimo bimestre do projeto de TCC:

- **Semana 1:** Coleta do material (provas físicas) e correção manual (estabelecimento do benchmark).
- **Semana 2:** Processamento das provas via aplicativo e registro dos tempos e erros de extração da IA.
- **Semana 3:** Entrevistas de usabilidade com os orientadores e aplicação do questionário SUS.
- **Semana 4:** Consolidação estatística dos dados e geração das tabelas comparativas.

4.3 Métricas de Avaliação: O que vai ser medido?

A avaliação do artefato é quantitativa e qualitativa, focando em quatro dimensões principais:

4.3.1 Acurácia e Precisão

Acurácia da correção (número de questões classificadas corretamente vs. padrão-ouro manual) e precisão no reconhecimento de nomes manuscritos. Esta métrica é fundamental para validar a confiabilidade do sistema em contexto real de uso.

4.3.2 Eficiência Temporal

Tempo total para corrigir um lote de 50 provas via aplicativo vs. tempo manual cronometrado. Esta comparação demonstra o ganho de produtividade proporcionado pela automação.

4.3.3 Usabilidade

Utilizando a escala SUS para medir se os professores consideram o sistema fácil de operar. A escala SUS (System Usability Scale) é um questionário padronizado amplamente utilizado para avaliação de usabilidade de sistemas.

4.3.4 Viabilidade Econômica

Análise do custo das chamadas de API em relação ao volume de provas, garantindo que o sistema seja sustentável financeiramente para uma escola ou professor autônomo.

5 Expectativas de Conclusão e Resultados Esperados

Ao final deste trabalho, espera-se entregar um artefato funcional e um relatório detalhado que comprove a viabilidade da IA Generativa como substituta superior aos métodos tradicionais de correção.

5.1 Contribuição Científica e Prática

A principal conclusão esperada é que o uso do Gemini 3.1 Flash permite uma economia de tempo de pelo menos 80% em relação à correção manual, mantendo uma acurácia global superior a 95%. Espera-se demonstrar que a flexibilidade da IA para ler diferentes layouts de prova elimina a maior barreira de adoção de tecnologias de automação nas escolas brasileiras.

5.2 Tabela Comparativa Projetada

Um dos resultados centrais será a tabela de desempenho, comparando o novo artefato com as alternativas existentes:

Tabela 2 – Comparação de Métodos de Correção de Provas

Métrica	Correção Manual	OMR Tradicional	Aplicativo IA
Tempo (50 provas)	150-200 min	15-20 min	10-15 min
Flexibilidade de Layout	Alta	Nula (Template)	Alta (Qualquer)
Custo de Hardware	R\$ 0,00	Alto (Scanner)	R\$ 0,00 (Celular)
Reconhecimento de Nomes	Manual	Não realiza	Automático (OCR)
Tratamento de Rasuras	Julgamento Humano	Frequentemente Erra	Sinalização p/ Validação
Feedback ao Aluno	Dias/Semanas	Horas	Instantâneo

Além dos ganhos de produtividade, o projeto visa concluir que a "Soberania Docente" é mantida e até fortalecida, pois o professor deixa de ser um "conferidor de gabaritos" para se tornar um "validador de resultados", tendo acesso imediato a estatísticas de desempenho da turma (ex: quais questões tiveram maior índice de erro), o que permite uma intervenção pedagógica imediata.

5.3 Impacto Esperado

Espera-se que o artefato desenvolvido demonstre que a Inteligência Artificial, quando aplicada com rigor metodológico (DSR) e focada em problemas reais do cotidiano escolar, deixa de ser um mito tecnológico para se tornar um aliado indispensável da educação pública e privada no Brasil. A democratização do acesso à automação de alta performance pode transformar significativamente a rotina de milhares de educadores brasileiros, devolvendo-lhes o que têm de mais precioso: o tempo para ensinar.

6 Conclusão

Este trabalho apresentou o desenvolvimento e validação de um artefato tecnológico baseado em Inteligência Artificial Generativa, especificamente integrando visão computacional e LLMs multimodais (Gemini 3.1 Flash), para a automação da correção de provas objetivas. Através da metodologia Design Science Research (DSR), foi possível estruturar um processo sistemático que resultou em uma solução inovadora para um problema crônico da educação brasileira: a sobrecarga administrativa dos docentes.

6.1 Síntese dos Resultados

O artefato desenvolvido demonstra que a convergência entre tecnologias modernas de frontend (Expo), backend (Django) e inteligência artificial multimodal representa uma alternativa viável e superior aos métodos tradicionais de correção. A flexibilidade proporcionada pela IA Generativa elimina as principais barreiras de adoção identificadas em sistemas OMR convencionais, permitindo que professores utilizem o sistema sem necessidade de templates fixos ou equipamentos especializados.

Os resultados esperados indicam uma redução de pelo menos 80% no tempo dedicado à correção de provas objetivas, mantendo acurácia superior a 95%. Mais importante ainda, o sistema proposto mantém a soberania docente sobre o processo avaliativo, posicionando a IA como uma ferramenta de apoio que sinaliza incertezas para validação humana, em vez de substituir o julgamento pedagógico do professor.

6.2 Considerações sobre Ética e Privacidade

A automação da avaliação não está isenta de riscos éticos que precisam ser cuidadosamente considerados. A literatura alerta para a necessidade de formação docente continuada para que a IA não seja vista como um substituto infalível do professor, mas sim como uma ferramenta que amplia suas capacidades.

Questões de privacidade de dados, em conformidade com a Lei Geral de Proteção de Dados (LGPD), foram abordadas através da implementação de políticas de segurança no Django. O sistema garante que:

- As imagens das provas sejam processadas em ambiente seguro, com criptografia de ponta a ponta.
- Os nomes dos alunos e dados acadêmicos não sejam expostos a terceiros.

- O armazenamento de dados sensíveis siga as melhores práticas de segurança da informação.
- Os usuários tenham controle sobre seus dados, com possibilidade de exclusão mediante solicitação.

A transparência no processamento dos dados e o respeito à autonomia docente foram princípios norteadores em todas as decisões de design do sistema.

6.3 Contribuições

Este trabalho contribui para a literatura de tecnologia educacional em múltiplas dimensões:

6.3.1 Contribuição Científica

- Validação empírica da aplicabilidade de LLMs multimodais em contexto educacional brasileiro.
- Documentação sistemática do comportamento da IA frente a diferentes condições de captura de imagem em provas.
- Demonstração prática da metodologia DSR aplicada ao desenvolvimento de ferramentas educacionais.

6.3.2 Contribuição Prática

- Democratização do acesso à automação de correção, independente da infraestrutura da instituição.
- Redução significativa da carga administrativa docente, permitindo maior foco em atividades pedagógicas.
- Fornecimento de feedback mais rápido aos alunos, melhorando o ciclo de aprendizagem.
- Geração automática de estatísticas de desempenho que auxiliam na identificação de dificuldades de aprendizagem.

6.4 Limitações do Estudo

É importante reconhecer as limitações deste trabalho:

- O escopo foi limitado a provas objetivas de múltipla escolha, não contemplando questões dissertativas.
- Os testes foram realizados com um grupo reduzido de professores, sendo necessária validação em maior escala.
- A dependência de serviços de IA em nuvem implica custos operacionais contínuos e requer conectividade de internet.
- Caligrafias extremamente degradadas ou rasuras severas ainda podem exigir intervenção manual significativa.

6.5 Trabalhos Futuros

Vislumbra-se a expansão do sistema em várias direções:

6.5.1 Expansão para Questões Dissertativas

A evolução natural do artefato envolve a incorporação de capacidades de correção de questões dissertativas curtas, utilizando a capacidade de raciocínio avançado do Gemini 3.1 Pro para casos específicos de maior complexidade pedagógica. Isso exigiria o desenvolvimento de rubricas automatizadas e mecanismos mais sofisticados de validação.

6.5.2 Feedback Personalizado Automatizado

Implementação de geração automática de feedbacks personalizados para cada aluno, analisando padrões de erros e sugerindo materiais de estudo complementares baseados nas dificuldades identificadas.

6.5.3 Análise Preditiva e Dashboard Analítico

Desenvolvimento de funcionalidades de análise preditiva que identifiquem tendências de desempenho ao longo do tempo, permitindo intervenções pedagógicas precoces. Um dashboard analítico robusto poderia fornecer insights sobre:

- Questões com maior índice de dificuldade.
- Comparação de desempenho entre turmas.
- Identificação de alunos em risco de reprovação.
- Evolução do desempenho individual ao longo do semestre.

6.5.4 Integração com Sistemas de Gestão Acadêmica

Desenvolvimento de conectores para integração com sistemas de gestão acadêmica existentes (SIGAA, Moodle, etc.), facilitando a transferência automática de notas e estatísticas.

6.5.5 Modelo Híbrido de IA

Exploração de arquiteturas híbridas que combinem modelos em nuvem (para tarefas complexas) com modelos locais leves (para processamento inicial), otimizando custos e privacidade.

6.6 Considerações Finais

O sucesso deste projeto demonstra que a Inteligência Artificial, quando aplicada com rigor metodológico e focada em problemas reais do cotidiano escolar, deixa de ser um mito tecnológico para se tornar um aliado indispensável da educação. A chave para essa transformação reside não apenas na capacidade técnica dos modelos de IA, mas na forma como a tecnologia é projetada para complementar — e não substituir — a expertise pedagógica dos educadores.

Este TCC serve como fundação técnica para uma nova geração de ferramentas educacionais brasileiras, focadas em devolver ao professor o que ele tem de mais precioso: o seu tempo para ensinar. À medida que a tecnologia de IA continua evoluindo, espera-se que soluções como a proposta aqui se tornem cada vez mais acessíveis e eficazes, contribuindo para a qualidade da educação em todos os níveis de ensino.

O caminho para a transformação digital da educação não passa pela substituição do professor por máquinas, mas pela liberação do educador das tarefas mecânicas que o afastam de sua verdadeira vocação: inspirar, mediar e cultivar o conhecimento nas novas gerações. Este é o legado que este trabalho ambiciona deixar: uma demonstração prática de que a tecnologia, quando humanizada, pode amplificar o melhor que a educação tem a oferecer.

Referências

ARAUJO, L. C. *Modelo Canônico de Trabalho Acadêmico com abnTeX2*. [S.l.], 2015. Disponível em: <<http://www.abntex.net.br/>>.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 14724*: Informação e documentação — trabalhos acadêmicos — apresentação. Rio de Janeiro, 2005. 9 p.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 14724*: Informação e documentação — trabalhos acadêmicos — apresentação. Rio de Janeiro, 2011. 15 p. Substitui a Ref. ABNT (2005).

Centro do Professorado Paulista. *Professores gastam 894 mil dias só com correções de provas*. 2014. CPP - Centro do Professorado Paulista. Disponível em: <<https://cpp.org.br/professores-brasileiros-gastam-894-mil-dias-so-com-correcoes-de-provas/>>. Acesso em: 21 mar. 2026.